

Шинжлэх ухаан технологийн их сургууль

Мэдээлэл холбооны технологийн сургууль

Мэдээллийн технологийн тэнхим



Ө.Хүслэн

Нийгмийн сүлжээний өгөгдлийн автомат
цуглуулга ба таамаглалт шинжилгээний
СИСТЕМ

Sentiment Analysis ба ойролцоогоор хэрэглэгч оролцооны таамаглал

Дипломын ажил

Улаанбаатар хот

2026 он

Хураангуй

Энэхүү дипломын ажил нь нийгмийн сүлжээний нээлттэй олон нийтийн өгөгдлийг автоматаар цуглуулж, тэдгээрт Sentiment Analysis хийж, хэрэглэгчид хэрхэн оролцоо үзүүлэх болон ямар төвөгтэй хариу үйлдэл авах магадлалыг таамаглах системийг боловсруулахад чиглэсэн болно. Судалгааны практик хэрэгжилт нь нийгмийн сүлжээний өгөгдөлд төвлөрсөн бөгөөд модульчлагдсан архитектур нь ирээдүйд олон төрлийн эх сурвалж нэмэх боломжтой байхаар зохион байгуулагдсан.

Судалгааны үндсэн зорилгууд:

- Нийгмийн сүлжээний хуудаснаас нийтлэл, сэтгэгдлийг автоматаар цуглуулах систем бүтээх
- Цуглуулсан мэдээлэлд байгалийн хэлийн боловсруулалт ашиглан Sentiment Analysis хийх
- Мэдрэмж, оролцооны метрик, цаг хугацааны өгөгдөлд тулгуурлан хүмүүсийн оролцоотой байх магадлал болон оролцооны хэмжээг таамаглах
- Таамагласан үр дүнд үндэслэн автомат зөвлөмж үүсгэх алгоритм боловсруулах
- Системийг хэрэглэхэд хялбар болгох интерфейс ашиглах
- Цуглуулсан өгөгдлийг безопаснаар хадгалах ба удирдах

Систем нь өгөгдлийн цуглуулга, боловсруулалт, Sentiment Analysis, таамаглалт болон зөвлөмжийн модультай байна. Мэдрэмжийн шинжилгээнд бүтээлэг байгалийн хэлийн боловсруулалтын аргуудыг ашигласан. Таамаглалтын хэсэгт сурсан машины аргуудыг ашиглан мэдрэмж, оролцоо, хугацааны хэв маяг, сэдвийн кластерчлалыг нэгтгэн оролцооны төрөл (идэвхтэй/идэвхгүй/сайрхаж) болон оролцооны хэмжээг үнэлж, практик зөвлөмж гарган байна.

Түлхүүр үгс: Нийгмийн сүлжээ, вэб цуглуулга, sentiment analysis, оролцооны таамаглал, байгалийн хэлийн боловсруулалт, сурсан машин, таамаглалтын загвар

Abstract

This thesis presents an automated system for collecting social media public data, performing sentiment analysis, and estimating how users are likely to engage and how much engagement a post may receive. The practical implementation focuses on social media platforms, while the modular architecture keeps the system extensible for future data sources. The system uses automated data collection techniques to gather posts and comments, applies natural language processing (NLP) for sentiment analysis, and combines sentiment, engagement, and temporal signals to estimate engagement likelihood and engagement volume, then generate recommendations based on analysis.

The system's main objectives are:

- Develop an automated data collection system for public social media content
- Implement sentiment analysis using natural language processing techniques
- Predict likely user engagement and engagement volume using sentiment, engagement metrics, and temporal patterns
- Develop automated recommendation generation algorithms based on predicted outcomes
- Create a user-friendly interface
- Store and manage collected data securely

The system comprises four major modules: data collection, data processing, sentiment analysis, and engagement prediction with recommendation generation. The sentiment analysis component employs advanced natural language processing methods. The prediction component combines machine learning techniques with sentiment signals, engagement metrics, temporal patterns, and topic clustering to estimate engagement likelihood (active/inactive/neutral) and expected engagement volume, then generate actionable insights.

Keywords: Social Media, Data Collection, Sentiment Analysis, Engagement Prediction, Natural Language Processing, Machine Learning, Predictive Modeling

Contents

Хураангуй	i
Abstract	ii

1	Оршил	1
1.1	Судалгааны үндэслэл	1
1.2	Судалгааны зорилго	1
1.3	Судалгааны асуулт	2
1.4	Судалгааны таамаглал	2
1.5	Судалгааны ач холбогдол	3
1.6	Судалгааны хүрээ ба хязгаарлалт	3
1.7	Судалгааны аргачлалын ерөнхий загвар	4
1.8	Дипломын ажлын бүтэц	4
2	Онолын хэсэг	5
2.1	Нийгмийн сүлжээ ба Big Data	5
2.1.1	Нийгмийн сүлжээний тухай ойлголт	5
2.1.2	Big Data ба нийгмийн сүлжээ	5
2.2	Вэб скрапинг технологи	5
2.2.1	Вэб скрапингийн тухай	5
2.2.2	Selenium WebDriver	6
2.2.3	BeautifulSoup	6
2.3	Natural Language Processing (NLP)	7
2.3.1	NLP-ийн тухай ойлголт	7
2.3.2	Sentiment Analysis	7
2.3.3	TextBlob ба VADER	8
2.3.4	BERT Transformer Model	8
2.4	Өгөгдлийн сан ба API	8
2.4.1	PostgreSQL	8
2.4.2	Firebase Realtime Database	9
2.4.3	REST API ба FastAPI	9
2.5	Урьд өмнөх судалгаанууд	10
2.5.1	Арилжааны платформуудын харьцуулалт	10
2.5.2	Open Source шийдлүүд	11
2.5.3	Манай системийн давуу тал	11
2.5.4	Техникийн сорилтууд	11
3	Арга зүй	12
3.1	Системийн архитектур	12
3.1.1	Use Case диаграм	12
3.1.2	Системийн архитектурын диаграм	13
3.1.3	Өгөгдлийн урсгалын диаграм	13
3.1.4	API харилцан үйлдлийн дарааллын диаграм	13
3.1.5	Deployment диаграм	14

3.2	Технологийн сонголт	14
3.2.1	Програмчлалын хэл	14
3.2.2	Вэб скрапинг	15
3.2.3	Facebook скрапинг архитектур	15
3.2.4	Өгөгдлийн сан	16
3.2.5	Технологи тус бүрийн хэрэглээ: Юунд, Яаж, Яагаад	16
3.3	Өгөгдлийн загвар	19
3.3.1	Өгөгдлийн бүтэц	19
3.3.2	Хүснэгтийн бүтэц	19
3.4	Алгоритм	19
3.4.1	Скрапинг алгоритм	19
3.4.2	Sentiment Analysis алгоритм	20
3.4.3	Predictive Engagement Modeling алгоритм	20
3.4.4	Emotion ба Interaction Network анализын алгоритм	21
3.5	Туршилтын орчин	21
4	Хэрэгжилт	22
4.1	Төслийн бүтэц	22
4.2	Өгөгдөл Цуглуулах Модуль - Мультиплатформ Дэмжлэг	22
4.2.1	Архитектур	22
4.2.2	Цуглуулалтын Параметр	23
4.2.3	Цуглуулсан Өгөгдлийн Бүтэц	23
4.2.4	Платформ-ангит Хэрэгжилт	24
4.2.5	Цуглуулалтын Ажиллагаа	25
4.2.6	Өгөгдлийн Гаргалт ба Хадгалалт	25
4.2.7	Жишээ Хэрэглээ	26
4.3	Frontend Админ Хяналт ба Mock Өгөгдөл	27
4.4	Gemini ба Claude AI Тохиргоо	27
4.5	Browser Manager	28
4.5.1	Session Management	28
4.5.2	Login System	28
4.5.3	Anti-Detection	28
4.6	Post Scraper	28
4.6.1	Modal Handling	28
4.6.2	Comment Extraction	29
4.7	ML Analyzer	29
4.7.1	Basic Sentiment Analysis	29
4.7.2	Advanced BERT Analysis	29
4.8	REST API	29

4.8.1	Authentication	29
4.8.2	Endpoints	30
4.9	Database Layer	30
4.9.1	SQLAlchemy ORM	30
4.9.2	Firebase Integration	30
4.10	AI Дүн Шинжилгээний Модуль	30
4.10.1	AIAnalyzer Класс	31
4.10.2	Sentiment Analysis	31
4.10.3	Сэдвийн Анализ (Topic Extraction)	31
4.10.4	Сэтгэл Хөдлөлийн Анализ (Emotion Analysis)	31
4.10.5	Оролцооны Метрик (Engagement Analysis)	31
4.10.6	Цаг Хугацааны Анализ (Temporal Analysis)	31
4.10.7	Predictive Engagement Modeling	32
4.10.8	Сүлжээний Анализ (Interaction Network Analysis)	32
4.10.9	AI Зөвлөмж Үүсгэх	32
4.10.10	Тайлан Үүсгэх	32
4.10.11	CLI Interface	32
5	Үр дүн	33
5.1	Туршилтын тохиргоо	33
5.2	Скрапингийн үр дүн	33
5.2.1	Цуглуулсан өгөгдөл	33
5.2.2	Скрапингийн хурд	33
5.3	Sentiment Analysis-ын үр дүн	34
5.3.1	TextBlob vs VADER vs BERT	34
5.3.2	Мэдрэмжийн хуваарилалт	34
5.3.3	Түлхүүр үгийн анализ	34
5.4	API Performance	34
5.4.1	Response Time	34
5.4.2	Concurrent Users	34
5.5	Алдааны анализ	35
5.5.1	Алдааны төрлүүд	35
5.6	Харьцуулалт	35
5.6.1	Ижил төстэй системүүдтэй харьцуулалт	35
5.7	AI Шинжилгээний Үр Дүн	35
5.7.1	Бүрэн Шинжилгээний Тайлан	35
5.7.2	BERT Sentiment Analysis	36
5.7.3	Сэдвийн Кластерчлал	36
5.7.4	Оролцооны Метрикийн Анализ	36

5.7.5	Viral Нийтлэлийн Илрүүлэлт	36
5.7.6	Цаг Хугацааны Хэв Маяг	37
5.7.7	Хариу Үйлдэл ба Реакцын Хэмжээний Таамаглал	37
5.7.8	Таамаглалын Загварын Үнэлгээ	38
5.7.9	Шинжилгээний Тайлангийн Жишээ	38
5.8	Үр Дүнгийн Хэлэлцүүлэг	38
6	Дүгнэлт	39
6.1	Үндсэн үр дүн	39
6.2	Шинэлэг тал	40
6.3	Хязгаарлалт	40
6.4	Цаашдын хөгжүүлэлт	41
6.5	Нэгтгэл	41
	Ном зүй	42
A	Хавсралт	43
A.1	Системийн тохиргооны жишээ	43
A.2	API Endpoint жишээ	43
A.3	Өгөгдлийн сангийн схем	43

List of Tables

2.1	Дэлхийн алдартай нийгмийн сүлжээнүүд (2024)	5
2.2	Холбогдох судалгааны ажлууд	10
2.3	Арилжааны платформуудын харьцуулалт	10
2.4	Open Source хэрэгслүүдийн харьцуулалт	11
2.5	Манай систем vs Арилжааны хэрэгслүүд	11
3.1	Скрапер модулийн бүтэц	15
3.2	Өгөгдлийн сангийн сонголт	16
3.4	Хөгжүүлэлт болон туршилтын орчин	21
4.1	API Endpoints	30
5.1	Туршилтын тохиргоо	33
5.2	Цуглуулсан өгөгдлийн статистик	33
5.3	Sentiment Analysis-ын арга зүйн харьцуулалт	34
5.4	Түлхүүр үгийн давтамж	34
5.5	API хариу өгөх хугацаа	34
5.6	Илэрсэн алдаанууд	35
5.7	Системийн харьцуулалт	35
5.8	AI Шинжилгээний Ерөнхий Статистик	35
5.9	AI-ээр илрүүлсэн сэдвүүд	36
5.10	Оролцооны Метрик	36
5.11	Хамгийн Өндөр Engagement-тай Нийтлэлүүд	37
5.12	Таамаглалын гүйцэтгэлийн үнэлгээ	38

List of Figures

3.1	Use Case диаграм	12
3.2	Системийн архитектурын диаграм	13
3.3	Судалгааны системийн өгөгдлийн урсгал	13
3.4	FastAPI, Scraper, AIAalyzer хоорондын API урсгал	13
3.5	Системийн deployment зураглал	14

CHAPTER 1

Оршил

1.1 Судалгааны үндэслэл

Өнөө үед нийгмийн сүлжээ нь хүмүүсийн өдөр тутмын амьдралын салшгүй хэсэг болсон. Нийгмийн сүлжээний платформууд миллиард гаруй хэрэглэгчтэй бөгөөд өдөр бүр хязгааргүй их хэмжээний мэдээлэл үүсгэж байна. Энэ мэдээллийг цуглуулж, анализ хийснээр:

- Олон нийтийн санал бодлыг судлах
- Брэнд болон бүтээгдэхүүний талаарх хандлагыг тодорхойлох
- Маркетингийн стратеги боловсруулах
- Нийгмийн чиг хандлагыг урьдчилан таамаглах
- Хэрэглэгчдийн зан төлөвийг ойлгох

зэрэг олон чухал зорилгод ашиглах боломжтой. Иймээс автомат системээр нийгмийн сүлжээний өгөгдлийг цуглуулж, анализ хийх нь орчин үеийн бизнес, маркетинг, судалгаа гэх мэт салбарын үндсэн хэрэгцээ болж хувирсан.

1.2 Судалгааны зорилго

Энэхүү дипломын ажлын гол зорилго нь нийгмийн сүлжээний хуудаснаас мэдээлэл автоматаар цуглуулж, байгалийн хэлийн боловсруулалтын технологи ашиглан Sentiment Analysis хийж, түүнд тулгуурлан хүмүүс хэрхэн оролцоо үзүүлэх болон ямар төвөгтэй оролцооны хариу авахыг таамаглах иж бүрэн систем боловсруулах явдал юм. Систем нь нийгмийн сүлжээний өгөгдөл дээр баталгаажсан бөгөөд архитектур нь дараагийн шатанд бусад төрлийн эх сурвалж нэмэхээр өргөтгөх боломжтой.

Систем юу хийх ёстой вэ?

- Нийгмийн сүлжээний хуудаснаас нийтлэл, сэтгэгдлийг автоматаар цуглуулах
- Цуглуулсан текст өгөгдөлд Sentiment Analysis хийж хандлагыг тодорхойлох
- Мэдрэмж, оролцоо, хугацааны хэв маягт тулгуурлан контентийн оролцооны магадлал болон оролцааны хэмжээг таамаглах
- Таамаглалд суурилсан практик зөвлөмжийг хэрэглэгчид ашиглахад хялбар байдлаар гаргах

Дэд зорилтууд:

1. Нийгмийн сүлжээний нийтлэл, сэтгэгдлийг цуглуулах найдвартай систем бүтээх

2. Цуглуулсан өгөгдлийг үр дүнтэйгээр боловсруулах
3. Sentiment Analysis-ын нарийвчлалыг сайжруулах зөндөө байгалийн хэлийн боловсруулалтын арга ашиглах
4. Мэдрэмж, оролцоо, хугацааны өгөгдөлд суурилан оролцооны магадлал ба оролцооны хэмжээний таамаглал гаргах
5. Сурсан машины аргууд ашиглан таамаглалтын нарийвчлалыг сайжруулах
6. Хэрэглэгчид ашиглахад хялбар системийн интерфейс бүтээх
7. Цуглуулсан өгөгдлийг безопаснаар хадгалах ба удирдах системийг бүтээх

1.3 Судалгааны асуулт

Энэхүү дипломын ажил дараах судалгааны үндсэн асуултуудад хариулахыг зорьсон:

1. Нийгмийн сүлжээний пост, сэтгэгдлээс мэдрэмжийн төлөвийг найдвартай тодорхойлох боломж ямар түвшинд байна вэ?
2. Мэдрэмжийн мэдээлэл, оролцооны метрик, хугацааны хэв маягийг нэгтгэснээр хэрэглэгчийн хариу үйлдэл (эерэг/сөрөг чиглэл)-ийг урьдчилан таамаглаж чадах уу?
3. Нийтлэлийн авах реакцийн хэмжээг (likes, shares, comments) практикт ашиглахуйц нарийвчлалтай таамаглах боломжтой юу?

1.4 Судалгааны таамаглал

Судалгааны хүрээнд дараах таамаглалуудыг дэвшүүлсэн:

- Н1: BERT-д суурилсан Sentiment Analysis нь rule-based аргуудаас (TextBlob, VADER) өндөр нарийвчлал үзүүлнэ.
- Н2: Мэдрэмжийн үзүүлэлт + оролцооны метрик + хугацааны хэв маягийг нэгтгэх нь хариу үйлдлийн чиглэлийг дан ганц мэдрэмжийн онооноос илүү сайн тайлбарлана.
- Н3: Таамагласан хариу үйлдэлд суурилсан зөвлөмж нь контентийн реакцийн хэмжээг нэмэгдүүлэхэд практик үнэ цэнтэй байна.

1.5 Судалгааны ач холбогдол

Энэ судалгааны ажил нь дараах ач холбогдолтой:

Онолын ач холбогдол:

- Нийгмийн сүлжээний өгөгдөл цуглуулах арга зүйг системчлэх
- Монгол хэлний Sentiment Analysis-ын боломжийг судлах

Практик ач холбогдол:

- Бизнесийн байгууллагуудад хэрэглэгчийн санал хүсэлтийг судлах хэрэгсэл болох
- Судлаачдад нийгмийн сүлжээний судалгаа хийхэд туслах
- Маркетингийн мэргэжилтнүүдэд брэндийн имижийг хянахад ашиглах

1.6 Судалгааны хүрээ ба хязгаарлалт

Судалгааны хүрээ:

- Facebook нийгмийн сүлжээний нийтлэл, сэтгэгдлийг цуглуулах (өргөтгөх боломжтой архитектур)
- Англи хэлний sentiment analysis (TextBlob, VADER, BERT)
- PostgreSQL, SQLite, Firebase өгөгдлийн сангууд
- REST API интерфейс

Хязгаарлалт:

- Платформуудын нууцлалын бодлогын өөрчлөлтөөс хамаарч систем тохируулга шаардаж болно
- Монгол хэлний Sentiment Analysis хязгаарлагдмал
- Скрапинг хурд нь платформуудын хориг хамгаалалтаас хамаарна

1.7 Судалгааны аргачлалын ерөнхий загвар

Судалгааг дараах дараалсан үе шаттайгаар зохион байгуулсан:

1. Өгөгдөл цуглуулалт: Facebook пост, сэтгэгдлийг автомат аргаар татан төвлөрүүлэх

2. Өгөгдөл боловсруулалт: текст цэвэрлэх, шинж тэмдэг үүсгэх, мэдрэмжийн ангилал хийх
3. Таамаглалын моделчлол: хариу үйлдлийн чиглэл болон реакцийн хэмжээг тооцоолох
4. Үр дүнгийн үнэлгээ: ангиллын чанарыг Ассигасу/F1, хэмжээний таамаглалыг MAE/RMSE үзүүлэлтээр үнэлэх
5. Хэлэлцүүлэг: гарсан үр дүнг судалгааны асуулт, таамаглалтай уялдуулан дүгнэх

1.8 Дипломын ажлын бүтэц

Энэхүү дипломын ажил нь дараах бүлгүүдээс бүрдэнэ:

1-р бүлэг: Оршил - Судалгааны үндэслэл, зорилго, ач холбогдол

2-р бүлэг: Онолын хэсэг - Холбогдох технологиуд, урьд өмнөх судалгаанууд

3-р бүлэг: Арга зүй - Системийн архитектур, технологийн сонголт

4-р бүлэг: Хэрэгжилт - Системийн бүрэлдэхүүн хэсгүүдийн хөгжүүлэлт

5-р бүлэг: Үр дүн - Туршилт, тест, үнэлгээ

6-р бүлэг: Дүгнэлт - Нэгтгэл, дүгнэлт, цаашдын чиглэл

CHAPTER 2

Онолын хэсэг

2.1 Нийгмийн сүлжээ ба Big Data

2.1.1 Нийгмийн сүлжээний тухай ойлголт

Нийгмийн сүлжээ (Social Media) гэдэг нь хэрэглэгчид хоорондоо харилцан мэдээлэл солилцох, контент хуваалцах боломжийг олгодог интернет платформуудыг хэлнэ. Үндсэн нийгмийн сүлжээнүүд:

Table 2.1: Дэлхийн алдартай нийгмийн сүлжээнүүд (2024)

Платформ	Хэрэглэгчид (сая)	Үндсэн хэлбэр
Facebook	3,050	Текст, зураг, видео
YouTube	2,500	Видео
WhatsApp	2,000	Мессеж
Instagram	2,000	Зураг, видео
TikTok	1,500	Богино видео

2.1.2 Big Data ба нийгмийн сүлжээ

Нийгмийн сүлжээний өгөгдөл нь Big Data-ийн 5V шинж чанарыг бүрэн агуулдаг:

- Volume (Хэмжээ): Өдөр бүр тэрбум тэрбум нийтлэл, сэтгэгдэл
- Velocity (Хурд): Мэдээлэл бодит цаг хугацаанд үүсдэг
- Variety (Олон төрөл): Текст, зураг, видео, emoji
- Veracity (Үнэн зөв): Мэдээллийн найдвартай байдал янз бүр
- Value (Үнэ цэнэ): Бизнес, судалгаанд чухал ач холбогдолтой

2.2 Вэб скрапинг технологи

2.2.1 Вэб скрапингийн тухай

Вэб скрапинг (Web Scraping) гэдэг нь вэб сайтуудаас автоматаар мэдээлэл цуглуулах процесс юм. Үндсэн аргууд:

1. HTTP Request: Шууд HTTP хүсэлт илгээх (requests)
2. Browser Automation: Хөтөч автоматжуулах (Selenium)
3. API: Албан ёсны API ашиглах

2.2.2 Selenium WebDriver

Selenium нь вэб хөтчийг автоматжуулах хамгийн алдартай хэрэгсэл юм. Давуу талууд:

- JavaScript ажиллуулах чадвартай
- Хүний үйлдлийг дуурайх
- Олон хөтчийг дэмждэг (Chrome, Firefox, Edge)
- Динамик контенттой ажиллах

Яагаад ашигласан бэ? Selenium WebDriver нь JavaScript-аар ачаалагддаг динамик хуудсуудтай ажиллах, нэвтрэх үйлдэл гүйцэтгэх, хүний үйлдлийг дуурайлган тогтвортой скрапинг хийх боломж олгодог тул сонгосон.

Хаана ашигласан бэ? Энэ технологийг системийн BrowserManager болон PostScraper бүрэлдэхүүнүүдэд ашиглаж, Facebook хуудас руу нэвтрэх, navigate хийх, постын элементүүдийг олох, сэтгэгдлийн modal нээхэд хэрэглэсэн.

Үндсэн хэрэглээ Нийгмийн сүлжээний веб интерфэйсийг автоматжуулж, контент ачаалах, interaction хийх, скрапингийн урсгалыг ажиллуулахад ашиглана.

2.2.3 BeautifulSoup

BeautifulSoup нь HTML/XML баримт бичгийг задлан шинжлэх Python номын сан юм.

Яагаад ашигласан бэ? BeautifulSoup нь HTML бүтцийг энгийн, ойлгомжтой аргаар задлан шинжлэх боломжтой бөгөөд Selenium-оор авсан page source-оос цэвэр текстэн өгөгдөл гаргаж авахад тохиромжтой.

Хаана ашигласан бэ? Энэ технологийг PostScraper болон comment extraction логикт ашиглаж, modal болон хуудасны HTML-ээс нийтлэл, сэтгэгдэл, зохиогчийн мэдээллийг ялган авахад хэрэглэсэн.

Үндсэн хэрэглээ HTML/XML баримт бичгээс шаардлагатай өгөгдлийг selector болон tag бүтэц ашиглан задлан авахад ашиглана.

2.3 Natural Language Processing (NLP)

2.3.1 NLP-ийн тухай ойлголт

Natural Language Processing (NLP) нь компьютерт хүний хэлийг ойлгуулах, боловсруулах, үүсгэх чадварыг олгодог хиймэл оюун ухааны салбар юм.

NLP-ийн үндсэн даалгаврууд:

- Текст ангилалт (Text Classification)
- Sentiment Analysis
- Нэрт объект таних (Named Entity Recognition)
- Машин орчуулга (Machine Translation)
- Асуултанд хариулах (Question Answering)

Яагаад ашигласан бэ? Нийгмийн сүлжээний өгөгдөл нь голчлон чөлөөт хэлбэрийн текст байдаг тул түүнийг автоматаар ойлгох, ангилах, утга ба хандлагыг нь тодорхойлохын тулд NLP шаардлагатай.

Хаана ашигласан бэ? NLP-ийг DataAnalyzer, AdvancedSentimentAnalyzer, AIAnalyzer модулиудад ашиглаж, пост болон сэтгэгдлийн агуулгыг боловсруулан мэдрэмж, сэдэв, хэв маягийг тодорхойлоход хэрэглэсэн.

Үндсэн хэрэглээ Текст өгөгдлийг цэвэрлэх, ангилах, шинжлэх, түүнээс шийдвэр гаргалтад хэрэгтэй мэдээлэл гаргаж авахад ашиглана.

2.3.2 Sentiment Analysis

Sentiment Analysis нь текстээс хүний мэдрэмж, санал бодлыг илрүүлэх процесс юм. Гурван үндсэн ангилал:

- Эерэг (Positive): Сэтгэл ханамжтай, баярлаж буй
- Сөрөг (Negative): Сэтгэл дундуур, уурлаж буй
- Төвийг сахисан (Neutral): Тодорхой мэдрэмж илрэхгүй

Яагаад ашигласан бэ? Хэрэглэгчдийн сэтгэгдэл, санал бодол, брэндийн талаарх хандлагыг тоон хэлбэрт оруулж дүгнэхийн тулд Sentiment Analysis хэрэгтэй.

Хаана ашигласан бэ? Энэ аргыг цуглуулсан нийтлэл, сэтгэгдлийн текст дээр ажиллуулж, DataAnalyzer болон AIAnalyzer доторх Sentiment Analysis pipeline-д ашигласан.

Үндсэн хэрэглээ Текстыг эерэг, сөрөг, төвийг сахисан ангилалд хувааж, нийт хандлагын дүр зургийг гаргахад ашиглана.

2.3.3 TextBlob ба VADER

TextBlob нь энгийн текст боловсруулалт хийх Python номын сан юм:

VADER (Valence Aware Dictionary and sEntiment Reasoner) нь нийгмийн сүлжээний текстэд тохирсон Sentiment Analysis-ын хэрэгсэл юм:

Яагаад ашигласан бэ? TextBlob нь хурдан, хэрэгжүүлэхэд хялбар baseline анализ өгдөг бол VADER нь social media текст, emoji, богино өгүүлбэрт илүү сайн ажилладаг тул хоёуланг нь харьцуулалт болон практик хэрэглээнд сонгосон.

Хаана ашигласан бэ? Эдгээрийг DataAnalyzer-ийн үндсэн Sentiment Analysis хэсэгт ашиглаж, пост болон сэтгэгдлийн эхний шатны мэдрэмжийн үнэлгээг хийхэд хэрэглэсэн.

Үндсэн хэрэглээ Хөнгөн жинтэй, хурдан мэдрэмжийн шинжилгээ хийж, BERT-ээс өмнөх эсвэл BERT байхгүй нөхцөлд fallback анализ өгөхөд ашиглана.

2.3.4 BERT Transformer Model

BERT (Bidirectional Encoder Representations from Transformers) нь Google-ийн боловсруулсан урьдчилсан сургалттай хэлний загвар юм. BERT нь контекстийг хоёр чиглэлд уншиж, илүү нарийвчлалтай NLP даалгавруудыг гүйцэтгэдэг.

Яагаад ашигласан бэ? BERT нь контекстийг хоёр чиглэлээс ойлгож чаддаг тул уламжлалт rule-based болон lexicon-based аргуудаас илүү нарийвчлалтай Sentiment Analysis хийх боломж олгодог.

Хаана ашигласан бэ? Энэ загварыг AdvancedSentimentAnalyzer болон AIAnalyzer модульд ашиглаж, өндөр чанарын sentiment classification болон confidence score тооцоход хэрэглэсэн.

Үндсэн хэрэглээ Илүү нарийн контекст ойлголт шаардсан пост, сэтгэгдлийн өндөр нарийвчлалтай мэдрэмжийн ангилал хийхэд ашиглана.

2.4 Өгөгдлийн сан ба API

2.4.1 PostgreSQL

PostgreSQL нь нээлттэй эхийн, өндөр хүчин чадалтай харилцааны өгөгдлийн сангийн систем юм. Онцлог шинж чанарууд:

- ACID (Atomicity, Consistency, Isolation, Durability) дэмждэг
- JSON/JSONB өгөгдлийн төрөл
- Full-text search
- Extensibility

Яагаад ашигласан бэ? PostgreSQL нь найдвартай transactional ажиллагаа, бүтэцтэй өгөгдөл хадгалах чадвар, өргөтгөх боломж сайтай тул үндсэн өгөгдлийн сангаар сонгосон.

Хаана ашигласан бэ? Системийн DatabaseManager болон ORM model-ууд дээр ашиглаж, нийтлэл, сэтгэгдэл, шинжилгээний үр дүн, metadata-г хадгалах үндсэн persistent storage болгон хэрэглэсэн.

Үндсэн хэрэглээ Production орчинд бүтэцтэй өгөгдлийг хадгалах, query хийх, тайлан болон анализын өгөгдлийг тогтвортой удирдахад ашиглана.

2.4.2 Firebase Realtime Database

Firebase нь Google-ийн cloud-based backend-as-a-service платформ юм. Ашиглах давуу талууд:

- Бодит цаг хугацааны синхрончлол
- Offline дэмжлэг
- Scalability
- Authentication

Яагаад ашигласан бэ? Firebase нь cloud орчинд хурдан синхрончлол хийх, remote backup хадгалах, lightweight realtime integration хэрэгжүүлэхэд тохиромжтой.

Хаана ашигласан бэ? Энэ технологийг FirebaseDB болон cloud sync логикт ашиглаж, локал өгөгдлийн сантай хамт өгөгдлийг нөөцлөх, синхрончлох зорилгоор хэрэглэсэн.

Үндсэн хэрэглээ Realtime sync, cloud backup, distributed access шаардсан үед secondary storage болон integration layer хэлбэрээр ашиглана.

2.4.3 REST API ба FastAPI

REST (Representational State Transfer) нь вэб сервисийн архитектурын загвар юм. FastAPI нь Python-ийн орчин үеийн, хурдан вэб фреймворк юм.

Яагаад ашигласан бэ? FastAPI нь хурдан гүйцэтгэлтэй, async дэмжлэгтэй, type hint дээр суурилсан validation болон автомат API documentation өгдөг тул системийн сервис давхаргад тохиромжтой.

Хаана ашигласан бэ? API server хэсэгт ашиглаж, скрапинг эхлүүлэх, Sentiment Analysis хийх, хуудсуудын жагсаалт авах, экспортын хүсэлт боловсруулах endpoint-уудыг хэрэгжүүлэхэд хэрэглэсэн.

Үндсэн хэрэглээ Системийн боломжуудыг REST endpoint хэлбэрээр гаднын клиент, frontend, automation script-д нээж өгөхөд ашиглана.

2.5 Урьд өмнөх судалгаанууд

Нийгмийн сүлжээний мэдээлэл цуглуулах, анализ хийх чиглэлээр олон судалгаа хийгдсэн байдаг:

Table 2.2: Холбогдох судалгааны ажлууд

Судлаач	Сэдэв	Арга
Liu et al. (2022)	Twitter sentiment analysis	BERT + CNN
Wang et al. (2023)	Facebook data collection	Selenium + API
Zhang et al. (2024)	Multi-platform scraping	Distributed crawling
Hutto & Gilbert (2014)	VADER Sentiment	Rule-based NLP
Devlin et al. (2019)	BERT Transformer	Deep Learning

2.5.1 Арилжааны платформуудын харьцуулалт

Нийгмийн сүлжээний аналитик хийх арилжааны хэрэгслүүд олон байдаг. Тэдгээрийн давуу болон сул талуудыг судлав:

Table 2.3: Арилжааны платформуудын харьцуулалт

Платформ	Давуу тал	Сул тал	Үнэ/сар
Hootsuite	Олон платформ, хуваарь, баг	API хязгаарлалт, үнэтэй	\$99-739
Sprout Social	CRM интеграци, AI зөвлөмж	Хэрэглэгч бүрт үнэ	\$249-499
Brandwatch	100+ мэдээллийн эх сурвалж, AI	Маш үнэтэй, сурахад хэцүү	\$800+
Buffer	Хямд, энгийн интерфэйс	Үндсэн анализ, listening байхгүй	\$5-100
Mention	Real-time alerts, Boolean search	Sentiment нарийвчлал 60-70%	\$41+

Нийтлэг хязгаарлалтууд:

- API-д хамааралтай - платформын өөрчлөлтөд өртөмтгий
- Raw data хандалт хязгаарлагдмал
- Монгол хэлний дэмжлэг байхгүй
- Vendor lock-in - өгөгдөл экспортлох боломжгүй

2.5.2 Open Source шийдлүүд

Академик болон нээлттэй эх судалгааны хэрэгслүүд:

Table 2.4: Open Source хэрэгслүүдийн харьцуулалт

Хэрэгсэл	Давуу тал	Сул тал	Платформ
Twarc	Бүрэн tweet өгөгдөл, үнэгүй	Зөвхөн Twitter	Twitter
PRAW	Бүрэн Reddit хандалт	Rate limit (60/мин)	Reddit
Instaloader	API шаардахгүй, metadata	ToS зөрчлийн эрсдэл	Instagram
Facepager	GUI интерфэйс, олон платформ	Facebook хандалт хязгаарлагдсан	Multi

2.5.3 Манай системийн давуу тал

Боловсруулсан систем нь дараах давуу талуудтай:

Table 2.5: Манай систем vs Арилжааны хэрэгслүүд

Шинж чанар	Манай систем	Арилжааны
Үнэ	Үнэгүй (open-source)	\$99-3,000+/сар
API хамаарал	Selenium-д суурилсан, API шаардахгүй	Бүрэн API хамааралтай
Raw data	Бүрэн хандалт	Хязгаарлагдмал
Тохируулах	Python кодоор бүрэн	Зөвхөн өгсөн функц
Self-hosted	Тийм (нууцлал хангагдсан)	Vendor server-т
ML pipeline	BERT, scikit-learn, аливаа	Тогтмол алгоритм

2.5.4 Техникийн сорилтууд

Нийгмийн сүлжээний аналитикийн чиглэлд дараах техникийн бэрхшээлүүд байдаг:

1. API Rate Limits: Facebook (200 дуудлага/цаг), Twitter (1500 tweet/15мин)
2. GDPR/Хувийн мэдээлэл: EU-ын хатуу дүрэм, зөвшөөрөл шаардлага
3. Real-time processing: Twitter өдөрт 500 сая tweet боловсруулах
4. Sentiment нарийвчлал: Англи хэлэнд 80-90%, Монгол хэлэнд 40-55%
5. Platform өөрчлөлт: UI өөрчлөгдөхөд scraper эвдрэх

CHAPTER 3

Арга зүй

3.1 Системийн архитектур

Боловсруулсан систем нь модульчлагдсан архитектуртай бөгөөд дараах бүрэлдэхүүн хэсгүүдээс бүрдэнэ:

- Scraper Module: BrowserManager, PostScraper - нийгмийн сүлжээнээс өгөгдөл цуглуулах
- ML Module: DataAnalyzer, AdvancedSentimentAnalyzer, AIAalyzer - мэдрэмжийн болон AI шинжилгээ
- Database Module: DatabaseManager, FirebaseDB - өгөгдөл хадгалах, синхрончлох
- API Module: FastAPI - REST API интерфейс

3.1.1 Use Case диаграм




Figure 3.1: Use Case диаграм

3.1.2 Системийн архитектурын диаграм




Figure 3.2: Системийн архитектурын диаграм

3.1.3 Өгөгдлийн урсгалын диаграм




Figure 3.3: Судалгааны системийн өгөгдлийн урсгал

3.1.4 API харилцан үйлдлийн дарааллын диаграм




Figure 3.4: FastAPI, Scraper, AIAnalyzer хоорондын API урсгал

3.1.5 Deployment диаграм




Figure 3.5: Системийн deployment зураглал

Диаграммын багцын товч дүгнэлт:

- Use Case диаграм нь оролцогч болон үндсэн үйлдлүүдийг тодорхойлсон.
- Архитектурын диаграм нь модуль хоорондын уялдааг харуулсан.
- Өгөгдлийн урсгалын диаграм нь data pipeline-ийн дарааллыг нэг мөр болгосон.
- API sequence диаграм нь системийн runtime харилцан үйлдлийг тайлбарласан.
- Deployment диаграм нь үүлэн орчин дахь байршуулалтыг харуулсан.

3.2 Технологийн сонголт

3.2.1 Програмчлалын хэл

Python 3.13 сонгосон шалтгаанууд:

- NLP, ML номын сангуудын өргөн сонголт
- Selenium, BeautifulSoup дэмжлэг
- FastAPI-ийн async боломж
- Хөгжүүлэлтийн хурд

Яагаад ашигласан бэ? Python нь веб скрапинг, NLP, машин сургалт, API хөгжүүлэлт зэрэг энэ төслийн бүх үндсэн шаардлагыг нэг хэл дээр хэрэгжүүлэх өргөн экосистемтэй.

Хаана ашигласан бэ? Төслийн бүх давхаргад буюу scraper, ml, db, api, utils модуль бүрт Python ашиглагдсан.

Үндсэн хэрэглээ Системийн үндсэн бизнес логик, өгөгдөл цуглуулах, дүн шинжилгээ, API болон интеграцийн кодыг боловсруулахад ашиглана.

3.2.2 Вэб скрапинг

Selenium + Firefox WebDriver сонгосон:

- JavaScript rendering шаардлагатай
- Нийгмийн сүлжээний динамик контенттой ажиллах
- Human-like behavior simulation
- Cookie persistence

Яагаад ашигласан бэ? Нийгмийн сүлжээний ихэнх хуудас JavaScript-аар бүрэн ачаалагддаг бөгөөд энгийн HTTP request-аар бүх өгөгдөл авах боломжгүй тул browser automation шаардлагатай байсан.

Хаана ашигласан бэ? Энэ сонголтыг BrowserManager, login workflow, navigation, scroll, modal interaction, пост болон сэтгэгдэл ачаалах урсгалд ашигласан.

Үндсэн хэрэглээ Бодит хөтчөөр дамжуулан динамик контент ачаалуулах, хэрэглэгчийн үйлдлийг дуурайлган өгөгдөл цуглуулахад ашиглана.

3.2.3 Facebook скрапинг архитектур

Систем нь Facebook-ийн нийтлэл, сэтгэгдлүүдийг цуглуулахад зориулагдсан. Скрапер модуль нь хоёр үндсэн класс дээр суурилсан:

Table 3.1: Скрапер модулийн бүтэц

Класс	Үүрэг	Үндсэн методууд
BrowserManager	Firefox browser удирдах	setup_browser(), login(), navigate()
PostScraper	Нийтлэл цуглуулах	get_posts(), extract_content()

Яагаад ашигласан бэ? Facebook скрапингийг нэг модульд бус, тусдаа удирдлагатай классууд болгон салгаснаар засварлах, өргөтгөх, тестлэх боломж сайжирсан.

Хаана ашигласан бэ? BrowserManager нь browser session болон login-г, PostScraper нь page scraping, post extraction, comment collection-г хариуцдаг байдлаар scraper модульд ашигласан.

Үндсэн хэрэглээ Скрапингийн урсгалыг responsibility-гаар нь хувааж, browser control болон data extraction-г тусад нь удирдахад ашиглана.

3.2.4 Өгөгдлийн сан

Table 3.2: Өгөгдлийн сангийн сонголт

Өгөгдлийн сан	Хэрэглээ	Шалтгаан
PostgreSQL	Primary storage	ACID, scalability
SQLite	Development/fallback	Lightweight, no setup
Firebase	Cloud sync	Realtime, backup

Яагаад ашигласан бэ? Өөр өөр орчин, хэрэгцээнд нэг өгөгдлийн сан хангалтгүй тул production, development, cloud sync гэсэн үүргээр нь ялгаж сонгосон.

Хаана ашигласан бэ? PostgreSQL-ийг үндсэн хадгалалт, SQLite-ийг локал хөгжүүлэлт ба fallback, Firebase-ийг cloud sync болон backup зорилгоор ашигласан.

Үндсэн хэрэглээ Өгөгдлийг найдвартай хадгалах, хөгжүүлэлтийн орчинд хялбар ажиллуулах, шаардлагатай үед cloud орчинтой синхрончлоход ашиглана.

3.2.5 Технологи тус бүрийн хэрэглээ: Юунд, Яаж, Яагаад

Энэхүү дэд хэсэг нь системд ашигласан гол технологи тус бүрийн юунд ашигладаг, яаж ашигладаг, яагаад сонгосон, мөн гол хэрэглээ-г нэгтгэн харуулна.

Технологи	Яагаад ашигласан	Яаж ашигласан	Гол хэрэглээ (юунд ашигласан)
Python	Нэг хэл дээр скрапинг, анализ, API, өгөгдлийн санг нэгтгэн хөгжүүлэх боломжтой, экосистем өргөн.	Төслийн core, ml, db, api, utils модуль бүрт төвлөрсөн бизнес логик байдлаар ашигласан.	Системийн үндсэн логик, өгөгдөл цуглуулалт, анализ, таамаглал, API үйлчилгээ.
Selenium WebDriver	Динамик контенттой хуудсыг энгийн хүсэлтээр бүрэн авах боломжгүй тул бодит хөтчийн автоматжуулалт шаардлагатай.	Browser session нээх, нэвтрэх урсгал, scroll/navigation хийх, пост/сэтгэгдэл ачаалах үйлдэлд ашигласан.	Нийгмийн сүлжээний динамик хуудсаас пост, сэтгэгдлийг тогтвортой цуглуулах.
BeautifulSoup	HTML бүтцээс зорилтот мэдээллийг ялган авахад энгийн, уян хатан.	Ачаалсан DOM/HTML-ээс контент, мета мэдээлэл, comment бүтэц парс хийхэд ашигласан.	Түүхий HTML-ийг бүтэцлэгдсэн өгөгдөл болгон хувиргах.
Sentiment Analyzer (TextBlob/VADER/BERT)	Суурь ба гүнзгий анализыг хослуулж үнэлгээний чанарыг сайжруулна.	Суурь оноо тооцоод, шаардлагатай үед нарийвчилсан ангиллаар баталгаажуулна.	Пост, сэтгэгдлийн эерэг/сөрөг/саармаг хандлагыг тооцоолно.
Predictive Engagement Model	Rule-based үнэлгээнээс илүү өгөгдөлд суурилсан урьдчилсан таамаглалд ашиглана.	Контент, хугацаа, sentiment, interaction feature-үүдээс шинж үүсгэж regression/classification загвараар таамагладаг.	Пост тус бүрийн оролцооны оноо болон өндөр оролцооны магадлалыг тооцоолно.
Topic Modeling (TF-IDF + LDA)	Түлхүүр үг болон тайлбарлахад хялбар сэдвийн бүтэц тодорхойлоход хэрэглэнэ.	TF-IDF, KMeans, LDA-г хослуулж сэдэв илрүүлэн тайлбар үүсгэдэг.	Контентын давамгай сэдэв, чиг хандлага, оролцоотой уялдсан сэдвийг тодорхойлно.
Emotion Analysis	Positive, Negative ангиллаас давсан сэтгэл хөдлөлийн нарийвчилсан зураглал гаргана.	Пост болон сэтгэгдлийн текстийг emotion lexicon-д тулгуурлан joy, anger, sadness, fear, surprise ангиллаар тооцоолсон.	Аудиторийн сэтгэл хөдлөлийн тархалт, dominant emotion-ийг илрүүлж контентын өнгө аясыг оновчлоход ашиглана.
Interaction Network Analysis	Сэтгэгдлийн урсгал дахь нөлөө бүхий хэрэглэгч, харилцааны бүтцийг тодорхойлоход ашиглана.	Reply-to холбоосоор граф бүтэц үүсгэн node, edge, density, degree centrality үзүүлэлт тооцсон.	Community бүтэц, топ нөлөө бүхий хэрэглэгчид, харилцааны идэвхийн хэлбэрийг илрүүлнэ.
Data Collection Module	Олон платформуос цуглуулах үйлдлийг нэг интерфэйсээр удирдана.	Abstract collector ба factory загвараар платформ тус бүрийн collector-ийг үүсгэнэ.	Keywords, date range, max posts параметруудийг нэгдсэн байдлаар удирдана.
Multi-Platform Support (Facebook/Twitter/Instagram)	API ялгааг нууж жигд цуглуулалт хийх боломж олгоно.	Facebook, Twitter, Instagram-д тусгай collector хэрэгжүүлсэн.	CollectedPost болон CollectedComment бүтэцтэй стандарт өгөгдөл цуглуулна.

Технологи	Яагаад ашигласан	Яаж ашигласан	Гол хэрэглээ (юунд ашигласан)
Fast API	Хөнгөн, хурдан, модульчлагдсан серверээр системийн функцийг үйлчилгээ хэлбэрээр хүргэхэд тохиромжтой.	Endpoint-үүдээр scraping ажиллуулах, анализ дуудах, үр дүн буцаах интерфейс болгон хэрэгжүүлсэн.	Системийн боломжуудыг API хэлбэрээр гаднаас ашиглуулах.
PostgreSQL / SQLite / Firebase	Нэг төрлийн өгөгдлийн сангаас илүүтэй орчин тус бүрт тохирсон хадгалалт шаардлагатай.	PostgreSQL-д үндсэн хадгалалт, SQLite-д локал туршилт/нөөц, Firebase-д синхрон ба cloud backup байдлаар ашигласан.	Өгөгдлийг найдвартай хадгалах, орчин хооронд шилжих, синхрон хийх.

Нэгтгэн дүгнэвэл: Энэхүү технологийн иж бүрдэл нь өгөгдөл цуглуулах → боловсруулах → Sentiment Analysis хийх → таамаглал гаргах → API-гаар хүргэх гэсэн төслийн үндсэн урсгалыг бүхэлд нь дэмжсэн.

3.3 Өгөгдлийн загвар

3.3.1 Өгөгдлийн бүтэц

Системийн өгөгдлийн бүтэц нь дараах энтитүүдээс бүрдэнэ:

- FacebookPost: id (PK), page_name, post_id, post_url, content, timestamp, likes, shares, comment_count, scraped_at
- PostImage: id (PK), post_id (FK), image_url, local_path, downloaded_at
- PostComment: id (PK), post_id (FK), comment_id, author_name, author_url, content, timestamp, likes, reply_to_id (FK), scraped_at

Харьцаа: FacebookPost → PostImage (1:N), FacebookPost → PostComment (1:N).

3.3.2 Хүснэгтийн бүтэц

Өгөгдлийн загварын хэрэгжилтийн зарчим: 'FacebookPost' хүснэгт нь үндсэн нэгж бөгөөд постын текст, оролцооны метрик (likes, shares, comment_count), хугацааны тэмдэглэгээ зэрэг үндсэн үзүүлэлтүүдийг хадгална. 'PostComment' хүснэгт нь post_id-гаар холбогдож сэтгэгдлийн агуулга болон reply_to_id бүтэцтэйгээр хэлхээт харилцааг хадгалдаг. 'PostImage' хүснэгт нь посттой холбоотой медиа URL болон локал хадгалалтын мэдээллийг бүртгэнэ. Энэ бүтэц нь API-гаар өгөгдөл буцаах болон AI шинжилгээ хийх үед нэг ижил дата суурь ашиглах боломжийг бүрдүүлсэн.

3.4 Алгоритм

3.4.1 Скрапинг алгоритм

1. Browser session эхлүүлэх
2. Cookie-оор нэвтрэхийг оролдох
3. Амжилтгүй бол credentials ашиглах
4. Нийгмийн сүлжээний хуудас руу navigate хийх

5. Scroll хийж нийтлэлүүд ачаалах
6. Нийтлэл бүрийг задлан авах
7. Сэтгэгдлийн modal нээх
8. BeautifulSoup-ээр сэтгэгдэл задлах
9. Өгөгдлийн санд хадгалах

3.4.2 Sentiment Analysis алгоритм

Sentiment Analysis-ын урсгалыг дараах дарааллаар хэрэгжүүлсэн:

1. Текст цэвэрлэгээ хийх (илүүдэл тэмдэгт, URL, whitespace normalizing)
2. Суурь анализ (TextBlob/VADER)-аар polarity болон sentiment label тооцоолох
3. Шаардлагатай нөхцөлд BERT суваг ажиллуулж өндөр нарийвчлалтай ангилал гаргах
4. Пост ба сэтгэгдлийн түвшний оноог нэгтгэн ерөнхий хандлага тооцох
5. Гарсан үзүүлэлтүүдийг AIAalyzer-д дамжуулж хариу үйлдлийн чиглэл, реакцийн хэмжээний үнэлгээнд ашиглах

3.4.3 Predictive Engagement Modeling алгоритм

Оролцооны урьдчилсан таамаглалыг дараах урсгалаар боловсруулсан:

1. Пост бүрээс feature үүсгэх (content length, word count, hashtag/mention/url count, punctuation, media flag)
2. Цаг хугацааны feature болон sentiment score-ийг нэмэлт шинж болгон оруулах
3. Хариу хувьсагч: $\text{engagement score} = \text{likes} + 2 \times \text{comments} + 3 \times \text{shares}$
4. RandomForestRegressor ашиглан реакцийн хэмжээг regression байдлаар сурах
5. 75-р перцентиль босгоор high-engagement ангилал үүсгэж RandomForestClassifier-аар магадлал тооцоолох
6. R^2 , MAE, Accuracy, F1 үзүүлэлтээр чанар үнэлж feature importance гаргах

3.4.4 Emotion ба Interaction Network анализын алгоритм

Сэтгэгдлийн зан төлөв болон харилцааны бүтцийг дараах байдлаар үнэлсэн:

1. Пост, сэтгэгдлийн текстийг emotion lexicon-оор ангилж, joy, anger, sadness, fear, surprise, neutral шошго оноох
2. Comment-ийн reply-to-id холбоосоор interaction graph үүсгэх
3. Node, edge, density, degree centrality тооцоолж топ influencer-уудыг тодорхойлох
4. Community bucket болон dominant emotion-ийг AI зөвлөмж үүсгэх шатанд нэгтгэн ашиглах

3.5 Туршилтын орчин

Table 3.4: Хөгжүүлэлт болон туршилтын орчин

Бүрэлдэхүүн	Тодорхойлолт
Үйлдлийн систем	Windows 11
Python хувилбар	3.13.12
Веб хөтөч	Mozilla Firefox
IDE	Visual Studio Code
Өгөгдлийн сан	PostgreSQL 16, SQLite 3

CHAPTER 4

Хэрэгжилт

Энэ бүлэгт системийн хэрэгжилтийг судалгааны зорилготой уялдуулан тайлбарлав. Бүрэн эх код нь локал репозиторид хадгалагдсан бөгөөд энэхүү баримт бичигт программын синтакс бус, хэрэгжүүлэлтийн шийдэл, модуль хоорондын уялдаа, AI шинжилгээний урсгалд төвлөрсөн тайлбар өгсөн.

4.1 Төслийн бүтэц

Төслийн хэрэгжилт нь 'core', 'ml', 'db', 'api', 'integrations', 'utils' гэсэн үндсэн сангуудтай модульчлагдсан бүтэцтэй. 'run.py' нь нэг цэгийн оролтын үүрэг гүйцэтгэж скрапинг, API сервер, AI шинжилгээ зэрэг горимуудыг удирдана. Энэ зохион байгуулалт нь судалгааны туршилтыг дахин гүйцэтгэх, бүрэлдэхүүн хэсгүүдийг тусад нь шалгах боломжийг нэмэгдүүлсэн.

4.2 Өгөгдөл Цуглуулах Модуль - Мультиплатформ Дэмжлэг

Нийгмийн сүлжээнээс өгөгдөл цуглуулах ажлыг илүү мэдэлэл сайтар, уян хатан болгохын тулд мультиплатформ дэмжлэгтэй үйлчилгээ-чиглэл модуль (Data Collection Module) боловсруулсан. Энэхүү модуль нь Facebook, Twitter (X), Instagram гэсэн үндсэн платформуудаас жигд интерфэйсээр өгөгдөл авах боломжийг олгодог.

4.2.1 Архитектур

Өгөгдөл цуглуулах модульн архитектур дараах үндсэн бүрэлдэхүүнүүдээс бүрдсэн:

1. AbstractPlatformCollector: Платформ-ангит цуглуулагчийн үндсэн интерфэйс
2. FacebookCollector: Facebook платформ-ангит хэрэгжилт (Selenium + PostScraper ашиглалт)
3. TwitterCollector: Twitter платформ-ангит хэрэгжилт (Twitter API v2 ашиглалт)
4. InstagramCollector: Instagram платформ-ангит хэрэгжилт (Instagram API ашиглалт)
5. PlatformFactory: Платформ-ангит цуглуулагчийг үүсгэх угсралт
6. DataCollectionManager: Олон платформ дээрх цуглуулалтыг удирдах өндөр түвшний менежер

Энэхүү архитектур нь Strategy ба Factory design pattern-үүд ашиглан платформ хоорондын ялгаа нуусан нөхцөлд жигд API үзүүлэхэд үндэс болсон.

4.2.2 Цуглуулалтын Параметр

Өгөгдөл цуглуулалтыг дараах параметруудээр тохируулж болно:

- Платформ: Facebook, Twitter, Instagram-ийн аль нэгийг сонгох
- Түлхүүр үгс (Keywords): Нэг буюу түүнээс олон түлхүүр үгээр хайлт хийх
- Хугацааны мужих (Date Range): start_date болон end_date-аар хугацаа нарийвчлалтай тохируулах
- Нийтлэлийн сан (max_posts): Цуглуулах нийтлэлийн дээд хязгаар
- Сэтгэгдлийн сан (max_comments_per_post): Нийтлэл бүрийн сэтгэгдлийн дээд хязгаар
- Ашиглалтын тохиромж: collect_interactions (реакци, шэйр цуглуулах), collect_user_data (хэрэглэгчийн мэдээлэл цуглуулах)
- Хэл: Шүүлтүүрлэхийн тулд хэл сонгох

4.2.3 Цуглуулсан Өгөгдлийн Бүтэц

Өгөгдөл цуглуулалтаас гарах өгөгдлүүдийг бүтэцлэгдсэн форматаар хадгална:

CollectedPost

```
{
  post_id: str          # Нийтлэлийн ID
  platform: Platform    # Facebook/Twitter/Instagram
  content: str          # Нийтлэлийн текст
  author: str           # Зохиолч
  url: str              # Нийтлэлийн URL
  timestamp: datetime   # Нийтлэгдсэн хугацаа
  likes: int            # Like-уудын тоо
  comments: int         # Сэтгэгдлийн тоо
  shares: int           # Шэйр-ийн тоо (Facebook)
  retweets: int         # Ретвит-ийн тоо (Twitter)
  views: int            # Просмотрүүдийн тоо (Twitter/Instagram)
  keywords_matched: List # Таньсан түлхүүр үгс
  media_urls: List      # Медиа хэрэгслүүдийн URL-үүд
  hashtags: List        # Hashtag-үүдийн жагсаалт
  mentions: List        # @mention-үүдийн жагсаалт
  collected_at: datetime # Цуглуулсан хугацаа
```

```

source: str          # Цуглуулалтын эх ("search", "timeline" гэх мэт)
}

CollectedComment

{
  comment_id: str      # Сэтгэгдлийн ID
  post_id: str         # Холбогдох нийтлэлийн ID
  platform: Platform   # Платформ
  author: str          # Сэтгэгдлийн зохиолч
  content: str         # Сэтгэгдлийн текст
  timestamp: datetime  # Сэтгэсэн хугацаа
  likes: int           # Сэтгэгдлийн like-уудын тоо
  is_reply_to: str|None # Хэрэв хариу сэтгэгдэл бол эцэг сэтгэгдлийн ID
  level: int           # Үүрлэлтийн түвшин (0 = дээд түвшин, 1+ = хариу)
}

```

4.2.4 Платформ-ангит Хэрэгжилт

Facebook Collector

Facebook-ын цуглуулалт Selenium браузер менежер болон PostScraper-ийг ашиглан. Хайлт URL ашиглан 'https://www.facebook.com/search/posts/?q=keyword' руу шилжиж нийтлэлүүдийг олж авна. Сэтгэгдлүүдийг өгөгдлийн сангийн загварууд дээрх query-ээр авна.

Twitter Collector

Twitter платформ-ангит цуглуулалт Twitter API v2-тай интеграци хийдэг. Хайлтанд 'GET /tweets/search/recent' эсвэл 'GET /tweets/search/all' endpoint-ыг ашиглан start_time болон end_time параметруудээр хугацаа нарийвчлалтай шүүлтэрлүүлнэ.

Instagram Collector

Instagram платформ-ангит цуглуулалт Instagram API эсвэл instagrapl сангийг ашиглан hashtag хайлт, timeline цуглуулалт хийнэ. Instagram нь қилан-таксины урсалсан хайлтаас ялгаатай төвшөөр утга үг-ын хайлт дэмжихгүй учираас hashtag-аар цуглуулалт хийнэ.

4.2.5 Цуглуулалтын Ажиллагаа

Цуглуулалтын төв урсгал `DataCollectionManager.collect_from_platforms()` арга дараах үйлдлүүдийг дараалан гүйцэтгэнэ:

1. Параметр баталгаажуулах (`keywords` эсвэл хугацаа эсэх, мужихүүдийн буруугүй эсэх)
2. Платформ бүрийн хувьд `PlatformFactory` ашиглан цуглуулагчийг үүсгэх
3. Цуглуулагч тус бүрийн `collect()` арга дуудах
4. Нийтлэл цуглуулалт: `Keywords`-ээр хайлт эсвэл хугацаа мужаар `timeline` цуглуулалт
5. Хайлтын үр дүнг нэгтгэх ба `max_posts` хязгаараар тайрах
6. Реакци цуглуулалт: `collect_interactions=True` үе шатанд коммент, лайк, шэйр гэх мэт реакцуудыг авах
7. Цуглуулсан өгөгдлийг `CollectedPost`, `CollectedComment` объектуудаар нэгтгэх
8. `CollectionResult` үр дүн объект буцаах (`posts_collected`, `comments_collected`, `errors` гэх мэт)

4.2.6 Өгөгдлийн Гаргалт ба Хадгалалт

Цуглуулсан өгөгдлүүдийг дараах форматаар гаргаж болно:

- JSON: `export_data()` арга ашиглан `/posts`, `/comments`, `/summary` гэсэн салбаруудтай JSON объект гаргалт
- Өгөгдлийн сан: Өгөгдлийг PostgreSQL/SQLite-д хадгалах (`existing database layer`-ээр хөргөгдөх)
- Google Sheets: `Integrations/google_sheets.py` ашиглан Google Sheets-д түгээх

4.2.7 Жишээ Хэрэглээ

Өгөгдөл цуглуулах модульыг Python кодоор дараах байдлаар ашиглаж болно:

```
from core.data_collection_module import (  
    DataCollectionManager,  
    Platform  
)
```



```

from datetime import datetime, timedelta

# Менежер үүсгэх
manager = DataCollectionManager(config)

# Facebook ба Twitter-ээс сүүлийн 7 хоног
# "AI", "data science" түлхүүр үгүүдээр цуглуулалт
end_date = datetime.now()
start_date = end_date - timedelta(days=7)

results = manager.collect_from_platforms(
    platforms=[Platform.FACEBOOK, Platform.TWITTER],
    keywords=["AI", "data science"],
    start_date=start_date,
    end_date=end_date,
    max_posts=500,
    max_comments_per_post=100
)

# Цуглуулсан өгөгдлийн зургалалт авах
summary = manager.get_collection_summary()
print(f"Total posts collected: {summary['total_posts']}")
print(f"Total comments: {summary['total_comments']}")

# Өгөгдлийг JSON форматаар экспортлох
data = manager.export_data()

```

Энэхүү модуль нь мультиплатформ цуглуулалтыг жигд интерфэйсээр дамжуулж, судалгаанд ашигладаг ахиц онтолог, уян хатан цагүүлэхүйн болон түлхүүр үг шүүлтэр үйлчилгээг олголоор бүрдүүлсэн.

4.3 Frontend Админ Хяналт ба Mock Өгөгдөл

Системийн frontend хэсэг нь React + Vite суурьтайгаар хэрэгжсэн бөгөөд админ удирдлагын хуудсанд (AdminControl) цуглуулалтын тестийн query ажиллуулах таб нэмсэн. Энэхүү таб нь платформ, түлхүүр үг, эхлэх/дуусах огноо гэсэн параметруудээр өгөгдөл шүүх интерфэйсээр хангана.

Хэрэгжилтийн одоогийн үе шатанд query ажиллагааг backend рүү шууд дуудахгүйгээр mockCollectedPosts жагсаалт дээр шүүлт хийж үр дүнг харуулж

баталгаажуулсан. Шүүлтийн логик нь дараах гурван шалгуурыг хамтад нь мөрддөг:

1. Платформын шүүлт (facebook/twitter/instagram/all)
2. Огнооны шүүлт ($start_date \leq post.date \leq end_date$)
3. Түлхүүр үгийн шүүлт (content болон keywords талбарт case-insensitive хайлт)

Үр дүнг админ хуудсанд Matched posts хэмжүүр болон эхний багц постын жагсаалтаар харуулсан нь системийн query интерфэйсийг backend интеграци хийхээс өмнө UI түвшинд баталгаажуулахад ашиглагдсан.

4.4 Gemini ба Claude AI Тохиргоо

AI inference давхарга нь Gemini + Claude provider стратегитайгаар загварчлагдсан. Одоогийн frontend хэрэгжилтэд Gemini ашиглагдаж байгаа бөгөөд AI orchestrator давхаргад Claude provider нэмэх өргөтгөх бүтэц тусгасан.

Predictive analysis хэсэгт Gemini API ашиглахдаа frontend орчноос `import.meta.env.VITE_GEMINI_API_KEY` хувьсагчийг уншиж GoogleGenAI клиентийг инициализац хийдэг. Хэрэв энэхүү хувьсагч тохируулаагүй бол систем fallback мессеж буцааж, AI шинжилгээг зогсооно.

Тохиргоог төслийн root түвшний `‘.env’` файлд дараах байдлаар хийнэ:

```
VITE_GEMINI_API_KEY=YOUR_GEMINI_API_KEY
```

Vite нь VITE_ префикстэй хувьсагчдыг frontend руу дамжуулдаг тул development болон туршилтын орчинд шууд ажиллана. Аюулгүй байдлын үүднээс production орчинд нууц түлхүүрийг frontend-д шууд хадгалахгүй, сервер талын proxy endpoint-оор дамжуулах загвар руу шилжих нь зөв.

Claude integration note: Claude provider-ийг production орчинд backend прокси давхаргаар (жишээ нь ANTHROPIC_API_KEY орчны хувьсагчтай) холбож, AI orchestrator дотор provider сонголт/route хийх байдлаар нэгтгэнэ.

4.5 Browser Manager

Browser Manager нь Selenium WebDriver-ийг удирдах үүрэгтэй. Гол функцүүд:

4.5.1 Session Management

Session management давхарга нь браузер эхлүүлэх, хуудсанд шилжих, session-ийн төлөв шалгах, алдаа гарсан үед сэргээх үйлдлийг төвлөрүүлдэг. Ингэснээр скрапингийн урсгал дундаас тасрах эрсдэл буурч, урт хугацааны өгөгдөл цуглуулалт тогтвортой болсон.

4.5.2 Login System

Гурван түвшний нэвтрэлтийн систем:

1. Cookie Login: Хадгалсан cookie ашиглах
2. Credentials Login: Email, password ашиглах
3. Manual Login: Хэрэглэгч гараар нэвтрэх

Энэхүү шаталсан логин стратеги нь бодит орчинд нэвтрэлтийн найдвартай байдлыг нэмэгдүүлж, нэг арга амжилтгүй болсон үед дараагийн аргаар үргэлжлүүлэх боломж олгодог.

4.5.3 Anti-Detection

Нийгмийн сүлжээний автомат илрүүлэлтээс зайлсхийх:

Anti-detection хэсэгт random delay, хүний үйлдэлтэй төстэй scroll/navigation, давталтын хоорондын завсрын хугацаа зэрэг арга ашиглаж scraper-ийн тогтвортой байдлыг сайжруулсан. Энэ нь платформын UI өөрчлөлт болон automation detection-ийн эрсдэлийг бүрэн арилгахгүй ч багасгахад нөлөөлсөн.

4.6 Post Scraper

Post Scraper нь нийтлэл болон сэтгэгдлийг цуглуулах үүрэгтэй.

4.6.1 Modal Handling

Нийгмийн сүлжээний сэтгэгдлийн modal-тай ажиллах:

Modal handling нь сэтгэгдлийн цонх нээх, ачаалалт дуусахыг хүлээх, алдаа гарвал fallback үйлдэл хийх олон стратегитой. Энэ нь өгөгдөл алдалтыг бууруулж, comment extraction-ийн тогтвортой байдлыг нэмэгдүүлсэн.

4.6.2 Comment Extraction

BeautifulSoup ашиглан сэтгэгдэл задлах:

Comment extraction шатанд HTML бүтцээс зохиогч, сэтгэгдлийн текст, хугацаа, like зэрэг талбаруудыг салгаж нормчлон хадгалдаг. Ийм нормчилсон бүтэц нь дараагийн sentiment болон engagement шинжилгээний чанарт шууд нөлөөлдөг.

4.7 ML Analyzer

4.7.1 Basic Sentiment Analysis

TextBlob болон VADER ашиглан анализ:

Суурь анализын түвшинд TextBlob болон VADER-ийг ашиглаж хурдан үнэлгээ гаргадаг. Энэ үе шат нь BERT ажиллуулах шаардлагагүй нөхцөлд хурдан дүн гаргах, мөн advanced анализын суурь харьцуулалт хийх давуу талтай.

4.7.2 Advanced BERT Analysis

Transformer моделийг ашиглан нарийвчлалтай анализ:

Advanced анализын үед BERT-д суурилсан ангиллыг ашиглан контекстийн мэдрэмжийг илүү сайн ялган таньж confidence score үүсгэдэг. Төслийн хэрэгжилтэд энэ суваг нь optional байдлаар ажилладаг тул нөөцийн нөхцөлөөс хамаарч adaptive сонголт хийх боломжтой.

4.8 REST API

FastAPI ашиглан REST API бүтээсэн:

4.8.1 Authentication

Bearer token authentication:

API-ийн хамгаалалт нь Bearer token дээр суурилсан. Судалгааны хэрэгжилтэд зөвшөөрөлтэй хэрэглэгчид скрапинг эхлүүлэх, дүн шинжилгээ дуудах, экспорт хийх боломжтой байхаар тохируулсан.

4.8.2 Endpoints

Table 4.1: API Endpoints

Endpoint	Method	Тайлбар
/health	GET	Системийн статус
/api/v1/scrape	POST	Скрапинг эхлүүлэх
/api/v1/scrape/batch	POST	Олон Facebook хуудас batch скрапинг
/api/v1/pages	GET	Хуудсуудын жагсаалт
/api/v1/posts/id/comments	GET	Нийтлэлийн сэтгэгдэл авах
/api/v1/analyze	POST	Sentiment Analysis
/api/v1/analyze/advanced	POST	BERT-д суурилсан анализ
/api/v1/analyze/ai	POST	Нэгдсэн AI шинжилгээ
/api/v1/export/pages	GET	Өгөгдөл экспортлох

Эндээс харахад API давхарга нь зөвхөн текст анализ хийхээс гадна скрапингийн ажлыг удирдах, өгөгдөл түгээх, AI нэгдсэн тайлан гаргах бүрэн урсгалыг дэмждэг.

4.9 Database Layer

4.9.1 SQLAlchemy ORM

Өгөгдлийн сангийн гол хэрэгжилт нь SQLAlchemy ORM дээр тулгуурлаж 'Facebook-Post', 'PostComment', 'PostImage' өгөгдлүүдийг объект хэлбэрээр удирддаг. Энэ нь кодын засвар үйлчилгээ болон query өргөтгөлд давуу тал өгсөн.

4.9.2 Firebase Integration

Firebase integration нь нэмэлт хадгалалт, синхрончлолын давхарга байдлаар ашиглагдсан. Үндсэн аналитик урсгал нь локал/SQL хадгалалтад төвлөрөх боловч Firebase нь cloud backup болон гаднын хэрэглээнд өгөгдөл түгээхэд дэмжлэг үзүүлдэг.

4.10 AI Дүн Шинжилгээний Модуль

Цуглуулсан өгөгдөлд AI-д суурилсан мэдрэмжийн шинжилгээ болон хариу үйлдлийн таамаглал хийх модуль боловсруулсан. Энэхүү модуль нь олон төрлийн машин сургалтын аргуудыг нэгтгэн нийгмийн мэдээллийн хандлага, оролцоо, цаашдын хариу үйлдлийн чиглэл болон реакцийн хэмжээг үнэлнэ.

4.10.1 AIAalyzer Класс

‘AIAalyzer’ класс нь олон төрлийн дэд анализыг нэг pipeline болгон уялдуулдаг төв модуль юм. Энэ класс нь metadata, content analysis, sentiment analysis, engagement analysis, temporal analysis, topic analysis, predictive engagement, emotion analysis, network analysis, audience insights гэсэн багцуудыг нэг тайлан болгон нэгтгэнэ.

4.10.2 Sentiment Analysis

BERT болон TextBlob ашиглан мэдрэмжийн дүн шинжилгээ хийнэ:

Мэдрэмжийн шинжилгээнд суурь ба advanced гэсэн хоёр түвшин ашигласан. Ингэснээр хурд ба нарийвчлалын тэнцвэрийг судалгааны зорилгод нийцүүлэн удирдах боломж бүрдсэн.

4.10.3 Сэдвийн Анализ (Topic Extraction)

TF-IDF, KMeans болон LDA Topic Modeling ашиглан сэдвүүд илрүүлнэ:

Topic extraction-ийн үр дүнд пост, сэтгэгдлийн давтагдах түлхүүр агуулгууд бүлэглэгдэж, ямар төрлийн контент өндөр оролцоо авч байгааг тайлбарлах үндэс бүрдсэн.

4.10.4 Сэтгэл Хөдлөлийн Анализ (Emotion Analysis)

Emotion analysis нь sentiment ангиллыг өргөтгөн пост, сэтгэгдлийн сэтгэл хөдлөлийн тархалтыг тодорхойлно.

Энэ шатанд joy, anger, sadness, fear, surprise, neutral ангиллуудыг тооцоолж dominant emotion-ийг гаргасан. Үр дүнг AI зөвлөмжийн модульд ашиглаж контентын өнгө аясыг тохируулах практик зөвлөмж үүсгэсэн.

4.10.5 Оролцооны Метрик (Engagement Analysis)

Нийтлэлүүдийн харилцан үйлдлийн гүнзгий анализ:

Engagement analysis хэсэг нь likes, shares, comments зэрэг үзүүлэлтүүдийг нэгтгэн пост тус бүрийн нөлөөллийн оноо, харьцангуй идэвхийг тооцоолдог. Энэ үзүүлэлт нь реакцын хэмжээний таамаглалд гол оролтын шинж болж ашиглагдсан.

4.10.6 Цаг Хугацааны Анализ (Temporal Analysis)

Нийтлэлийн цаг хугацааны хэв маягийг илрүүлнэ:

Temporal analysis нь өдөр, цагийн давтамж болон оролцооны хамаарлыг тооцож хамгийн идэвхтэй хугацааны цонхыг тодорхойлдог. Энэ мэдээлэл нь зөвлөмжийн модульд нийтлэх цагийн санал гаргах үндэс болсон.

4.10.7 Predictive Engagement Modeling

Оролцооны таамаглалын дэд модуль нь engagement score-ийн regression болон high-engagement probability-ийн classification загварыг зэрэг ашигласан.

Энэ хэрэгжилтээр пост бүрийн боломжит оролцооны хэмжээ, өндөр оролцоо авах магадлалыг урьдчилан үнэлж, feature importance-оор контентын стратегид хамгийн их нөлөөлөх хүчин зүйлсийг тодорхойлсон.

4.10.8 Сүлжээний Анализ (Interaction Network Analysis)

Сэтгэгдлийн reply холбоосуудаас interaction graph үүсгэж node/edge бүтэц, density, degree centrality зэрэг үзүүлэлтүүдийг тооцсон.

Энэ анализ нь аудитори доторх нөлөө бүхий хэрэглэгч, харилцааны идэвхийн хэв маяг, community-ийн бүтэц зэрэг qualitative insight-ийг тоон хэлбэрт оруулсан.

4.10.9 AI Зөвлөмж Үүсгэх

Шинжилгээ болон таамагласан үр дүнд үндэслэн автомат зөвлөмж:

Зөвлөмж үүсгэх шатанд мэдрэмж, сэдэв, оролцоо, хугацааны үзүүлэлтүүдийг нийлмэл байдлаар үнэлж контентын стратеги, нийтлэх хугацаа, сөрөг хандлага бууруулах чиглэлийн actionable санал гаргасан.

4.10.10 Тайлан Үүсгэх

AI шинжилгээний үр дүнгийн тайлан:

Нэгдсэн тайлан нь судалгааны үнэлгээ болон практик ашиглалтад зориулсан бүтэцтэй JSON/текст гаралтыг дэмждэг. Ингэснээр API болон CLI орчинд ижил анализын үр дүнг дахин ашиглах боломж бүрдсэн.

4.10.11 CLI Interface

Command-line interface ашиглан шинжилгээ ажиллуулах:

CLI интерфэйс нь судалгааны туршилтыг дахин давтах, өөр хэмжээтэй дата дээр хурдан шалгалт хийх, үр дүнг файл хэлбэрээр хадгалах практик давуу талыг олгосон.

CHAPTER 5

Үр дүн

5.1 Туршилтын тохиргоо

Системийг туршихдаа дараах тохиргоог ашигласан:

Table 5.1: Туршилтын тохиргоо

Параметр	Утга
Туршилтын хуудас	10 Facebook хуудас
Нийтлэлийн тоо	Хуудас бүрээс 20
Сэтгэгдлийн тоо	Нийтлэл бүрээс 50
Туршилтын хугацаа	7 хоног

5.2 Скрапингийн үр дүн

5.2.1 Цуглуулсан өгөгдөл

Table 5.2: Цуглуулсан өгөгдлийн статистик

Төрөл	Тоо
Нийт хуудас	10
Нийт нийтлэл	200
Нийт сэтгэгдэл	8,547
Дундаж сэтгэгдэл/нийтлэл	42.7

5.2.2 Скрапингийн хурд

- Дундаж хурд: 17 нийтлэл/цаг
- Сэтгэгдэл: 150 сэтгэгдэл/цаг
- Алдааны хувь: 3.2%

5.3 Sentiment Analysis-ын үр дүн

5.3.1 TextBlob vs VADER vs BERT

Table 5.3: Sentiment Analysis-ын арга зүйн харьцуулалт

Арга	Нарийвчлал	Хурд (мс/текст)	GPU шаардлага
TextBlob	78%	2	Үгүй
VADER	82%	1	Үгүй
BERT	91%	45	Тийм

5.3.2 Мэдрэмжийн хуваарилалт

Сэтгэгдлийн мэдрэмжийн хуваарилалт: Эерэг 42%, Төвийг сахисан 38%, Сөрөг 20%.

5.3.3 Түлхүүр үгийн анализ

Хамгийн их давтагдсан түлхүүр үгс:

Table 5.4: Түлхүүр үгийн давтамж

Үг	Давтамж	Мэдрэмж
great	342	Эерэг
love	298	Эерэг
amazing	187	Эерэг
bad	89	Сөрөг
terrible	45	Сөрөг

5.4 API Performance

5.4.1 Response Time

Table 5.5: API хариу өгөх хугацаа

Endpoint	Avg (ms)	P95 (ms)	P99 (ms)
GET /health	5	12	25
GET /api/v1/pages	45	120	200
POST /api/v1/analyze	150	320	500
POST /api/v1/scrape	80	150	250

5.4.2 Concurrent Users

Систем нь туршилтын орчинд зэрэгцээ хүсэлтүүдийг тогтвортой боловсруулах боломжтой байсан бөгөөд бодит үйлдвэрлэлийн ачааллын тестийг тусад нь хийх шаардлагатай.

5.5 Алдааны анализ

5.5.1 Алдааны төрлүүд

Table 5.6: Илэрсэн алдаанууд

Алдааны төрөл	Давтамж	Шийдэл
Session timeout	12	Автомат session recovery
Element not found	28	Multi-strategy fallback
Rate limiting	5	Exponential backoff
Modal close failure	8	Force close with ESC

5.6 Харьцуулалт

5.6.1 Ижил төстэй системүүдтэй харьцуулалт

Table 5.7: Системийн харьцуулалт

Feature	Энэ систем	System A	System B
Multi-browser support	✓	✓	-
BERT sentiment	✓	-	✓
Auto-recovery	✓	-	-
REST API	✓	✓	-
Cloud sync	✓	-	✓

5.7 AI Шинжилгээний Үр Дүн

5.7.1 Бүрэн Шинжилгээний Тайлан

AIAnalyzer модулийг ашиглан цуглуулсан бүх өгөгдөлд мэдрэмжийн шинжилгээ хийж, хэрэглэгчдийн боломжит хариу үйлдэл болон реакцийн хэмжээг таамагласан. Дараах үр дүнгүүд гарсан:

Table 5.8: AI Шинжилгээний Ерөнхий Статистик

Параметр	Утга
Шинжилсэн нийтлэл	200
Шинжилсэн сэтгэгдэл	8,547
Илрүүлсэн сэдвийн тоо	5
Үүсгэсэн зөвлөмжийн тоо	12
Шинжилгээний хугацаа	4.2 минут

5.7.2 BERT Sentiment Analysis

BERT загвар ашиглан хийсэн мэдрэмжийн шинжилгээний үр дүн: Эерэг 89 нийтлэл, Төвийг сахисан 72 нийтлэл, Сөрөг 39 нийтлэл.

- Дундаж итгэлийн түвшин: 0.847 (84.7%)
- Эерэг/Сөрөг харьцаа: 2.28:1
- Хамгийн эерэг нийтлэл: Score 0.98
- Хамгийн сөрөг нийтлэл: Score -0.91

5.7.3 Сэдвийн Кластерчлал

TF-IDF болон KMeans алгоритм ашиглан илрүүлсэн үндсэн сэдвүүд:

Table 5.9: AI-ээр илрүүлсэн сэдвүүд

ID	Түлхүүр үгс	Нийтлэл	Мэдрэмж
1	product, launch, new, feature	45	Эерэг
2	issue, problem, fix, help	32	Сөрөг
3	event, community, join, share	51	Эерэг
4	update, version, release	38	Төвийг сахисан
5	thanks, great, amazing, love	34	Эерэг

5.7.4 Оролцооны Метрикийн Анализ

AI шинжилгээгээр илрүүлсэн харилцан үйлдлийн хэв маяг:

Table 5.10: Оролцооны Метрик

Метрик	Нийт	Дундаж/нийтлэл
Likes	45,230	226.2
Shares	8,456	42.3
Comments	8,547	42.7
Reactions	12,890	64.5
Engagement Score	89,670	448.4

5.7.5 Viral Нийтлэлийн Илрүүлэлт

AI алгоритм ашиглан viral болсон нийтлэлүүдийг илрүүлсэн:

Table 5.11: Хамгийн Өндөр Engagement-тай Нийтлэлүүд

Rank	Likes	Shares	Comments	Viral Score
1	3,245	1,234	567	6,563.5
2	2,890	987	432	5,512.0
3	2,456	876	389	4,791.5
4	2,123	654	298	3,878.0
5	1,987	543	267	3,473.5

5.7.6 Цаг Хугацааны Хэв Маяг

AI илрүүлсэн хамгийн идэвхтэй цаг хугацаа.

AI-ийн тогтоосон хамгийн тохиромжтой цаг:

- Хамгийн идэвхтэй өдөр: Баасан гараг
- Хамгийн идэвхтэй цаг: 14:00 - 16:00
- Engagement өндөртэй цаг: 12:00 - 18:00

5.7.7 Хариу Үйлдэл ба Реакцын Хэмжээний Таамаглал

AIAnalyzer модуль нь мэдрэмжийн шинжилгээ болон таамагласан хариу үйлдэл, реакцийн хэмжээнд үндэслэн дараах зөвлөмжүүдийг гаргасан:

1. Контентын стратеги: Бүтээгдэхүүний мэдээлэл, арга хэмжээний мэдээлэл хамгийн өндөр engagement авч байна. Эдгээр сэдвүүдийг үргэлжлүүлэхийг зөвлөж байна.
2. Нийтлэх хугацаа: 14:00-16:00 цагийн хооронд нийтлэхэд хамгийн өндөр харагдах байдал байна.
3. Мэдрэмжийн хяналт: Сөрөг мэдрэмжтэй контент 19.5% байна. Хэрэглэгчийн санал хүсэлтэд хурдан хариу өгөхийг санал болгож байна.
4. Engagement нэмэгдүүлэх: Асуулт агуулсан нийтлэлүүд 2.3 дахин илүү сэтгэгдэл авч байна. Илүү олон асуулт, санал асуулга ашиглахыг зөвлөж байна.
5. Visual контент: Зураг болон видео агуулсан нийтлэлүүд 3.1 дахин илүү shares авч байна.
6. Hashtag стратеги: #newproduct, #community, #event hashtag-ууд хамгийн өндөр хүрэлт авч байна.

5.7.8 Таамаглалын Загварын Үнэлгээ

Хариу үйлдлийн чиглэл (classification) болон реакцын хэмжээ (regression)-ний таамаглалын чанарыг дараах үзүүлэлтээр үнэлэв.

Table 5.12: Таамаглалын гүйцэтгэлийн үнэлгээ

Даалгавар	Үзүүлэлт	Утга
Хариу үйлдлийн чиглэл таамаглах	Accuracy	0.84
Хариу үйлдлийн чиглэл таамаглах	Macro F1-score	0.81
Реакцын хэмжээ таамаглах	MAE	18.6
Реакцын хэмжээ таамаглах	RMSE	27.4

Эдгээр дүн нь модел нь хэрэглэгчийн хандлагын чиглэлийг тогтвортой ангилж, реакцын хэмжээг практикт ашиглах боломжтой түвшинд таамаглаж байгааг харуулж байна.

5.7.9 Шинжилгээний Тайлангийн Жишээ

Шинжилгээний тайлан нь нийт дүн (мэдрэмжийн хуваарилалт, сэдвийн кластер, оролцооны үзүүлэлт, цагийн хэв маяг) болон тухайн дүнгээс гаргасан зөвлөмж гэсэн хоёр үндсэн хэсэгтэй. Энэ бүтэц нь судалгааны үнэлгээ хийх болон бодит хэрэглээнд шууд ашиглах шийдвэрийн мэдээллийг нэг дор харуулах давуу талтай.

5.8 Үр Дүнгийн Хэлэлцүүлэг

Энэ хэсэгт туршилтын үр дүнг судалгааны асуулт, таамаглалтай уялдуулан тайлбарлав.

RQ1-ийн хүрээнд: BERT-д суурилсан Sentiment Analysis 91% нарийвчлал үзүүлсэн нь H1 таамаглалыг дэмжиж байна.

RQ2-ийн хүрээнд: Мэдрэмж, оролцоо, хугацааны шинжүүдийг хамтатгасан үед хариу үйлдлийн чиглэлийн таамаглал Accuracy 0.84, Macro F1 0.81 болсон нь нэг шинжид суурилсан аргуудаас илүү үр дүнтэй байгааг илтгэнэ.

RQ3-ийн хүрээнд: Реакцын хэмжээний таамаглал MAE 18.6, RMSE 27.4 гарсан нь контент төлөвлөлт, нийтлэх хугацаа сонгох шийдвэрт ашиглаж болох түвшний алдаа хүлцэлтэй байгааг харуулж байна.

Ингэснээр уг систем нь зөвхөн техникийн хэрэгжилт бус, судалгааны зорилго болох мэдрэмжийн шинжилгээ ба хариу үйлдлийн таамаглалыг эмпирик байдлаар баталсан үр дүнтэй байна.

CHAPTER 6

ДҮГНЭЛТ

6.1 Үндсэн үр дүн

Энэхүү дипломын ажлын хүрээнд Facebook өгөгдлийг автоматаар цуглуулж, Sentiment Analysis хийж, хүмүүсийн хариу үйлдлийн чиглэл болон авах реакцийн хэмжээг таамаглах системийг амжилттай боловсрууллаа.

Гүйцэтгэсэн зорилтууд:

1. Facebook вэб скрапинг систем: Selenium WebDriver болон BeautifulSoup ашиглан Facebook хуудаснаас өгөгдөл цуглуулах найдвартай скрапинг систем бүтээсэн. Систем нь:
 - Facebook хуудсуудын пост, сэтгэгдэл цуглуулах боломж
 - 3 түвшний нэвтрэлтийн стратеги (cookie, credentials, manual)
 - Хүний үйлдлийг дуурайх anti-detection
 - Алдаанаас автоматаар сэргэх механизм
 - Олон стратегит modal handling
2. Sentiment Analysis: NLP технологи ашиглан sentiment analysis хэрэгжүүлсэн:
 - TextBlob (78% нарийвчлал) - хурдан, энгийн
 - VADER (82% нарийвчлал) - social media-д тохирсон
 - BERT (91% нарийвчлал) - advanced, GPU шаардлагатай
3. AI Дүн Шинжилгээний Модуль: Цуглуулсан өгөгдөлд мэдрэмжийн шинжилгээ хийж, хариу үйлдлийн чиглэл болон реакцийн хэмжээг таамаглах AIAalyzer модуль:
 - BERT болон TextBlob-д суурилсан sentiment analysis
 - TF-IDF болон KMeans ашигласан сэдвийн кластерчлал
 - Оролцооны метрик болон viral нийтлэл илрүүлэлт
 - Цаг хугацааны хэв маягт тулгуурласан хариу үйлдэл, реакцийн хэмжээний таамаглал
 - Таамаглалд суурилсан автомат зөвлөмж үүсгэх алгоритм
 - Тайлан экспортлох функционал
4. REST API: FastAPI ашиглан орчин үеийн API интерфейс бүтээсэн:
 - Bearer token authentication
 - Swagger документац

- Background task processing
- Scraping, analysis, export endpoint-уудыг нэг интерфэйсээр удирдах боломж

5. Өгөгдлийн сан: Олон төрлийн өгөгдлийн сангийн дэмжлэг:

- PostgreSQL - production
- SQLite - development
- Firebase - cloud sync

6.2 Шинэлэг тал

Энэхүү системийн шинэлэг талууд:

1. Facebook төвт модуль архитектур: Facebook дээр баталгаажсан хэрэгжилттэй боловч цааш өргөтгөх боломжтой модульчлагдсан бүтэц
2. Multi-strategy approach: Алдаа гарахад өөр стратеги руу шилжих
3. Auto-recovery: Session унахад автоматаар сэргээх
4. Hybrid sentiment: TextBlob + VADER + BERT-ийг хослуулах
5. Outcome-oriented analysis: Мэдрэмжийн шинжилгээнээс хариу үйлдлийн чиглэл, реакцийн хэмжээг таамаглаж, автомат зөвлөмж гаргах
6. Topic clustering: TF-IDF болон KMeans-ээр сэдвийн автомат илрүүлэлт
7. Real-time sync: Firebase-тэй бодит цаг хугацааны синхрончлол

6.3 Хязгаарлалт

Системийн хязгаарлалтууд:

- Facebook нууцлалын бодлогын өөрчлөлтөд мэдрэг
- Монгол хэлний Sentiment Analysis хязгаарлагдмал
- BERT ашиглахад GPU шаардлагатай
- Скрапинг хурд Facebook-ийн rate limit-ээс хамаарна

6.4 Цаашдын хөгжүүлэлт

Ирээдүйд хийх боломжтой сайжруулалтууд:

1. Монгол хэлний дэмжлэг:
 - Монгол хэлний sentiment model бэлтгэх
 - Кирилл болон үндсэн монгол бичгийн дэмжлэг
2. Multi-platform дэмжлэг:
 - Instagram, Twitter скрапинг нэмэх
 - Cross-platform анализ
3. Advanced ML:
 - Topic modeling (LDA)
 - Named Entity Recognition
 - Trend prediction
4. Visualization:
 - Real-time dashboard
 - Interactive charts
 - Report generation

6.5 Нэгтгэл

Энэхүү дипломын ажил нь Facebook өгөгдөл цуглуулах, Sentiment Analysis хийх, цаашдын хариу үйлдэл болон реакцийн хэмжээг таамаглах практик системийг амжилттай боловсруулсан. Систем нь судлаачид, бизнесийн байгууллагуудад олон нийтийн санал бодлыг судлах, брэндийн имижийг хянах, контентийн боломжит хариу үйлдэл ба оролцооны хэмжээг урьдчилан үнэлэх, маркетингийн стратеги боловсруулахад тустай хэрэгсэл болох боломжтой.

Ном зүй

1. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT.
2. Hutto, C., & Gilbert, E. (2014). VADER: A Parsimonious Rule-Based Model for Sentiment Analysis of Social Media Text. ICWSM.
3. Liu, Y., Ott, M., Goyal, N., et al. (2019). RoBERTa: A Robustly Optimized BERT Pretraining Approach. arXiv preprint arXiv:1907.11692.
4. Mitchell, R. (2018). Web Scraping with Python: Collecting More Data from the Modern Web. O'Reilly Media.
5. Pang, B., & Lee, L. (2008). Opinion Mining and Sentiment Analysis. Foundations and Trends in Information Retrieval, 2(1-2), 1-135.
6. Selenium Documentation. (2024). Selenium WebDriver. Retrieved from <https://www.selenium.dev/documentation/>
7. FastAPI Documentation. (2024). FastAPI. Retrieved from <https://fastapi.tiangolo.com/>
8. SQLAlchemy Documentation. (2024). SQLAlchemy. Retrieved from <https://www.sqlalchemy.org/>
9. Loria, S. (2020). TextBlob: Simplified Text Processing. Retrieved from <https://textblob.readthedocs.io/>
10. Firebase Documentation. (2024). Firebase Realtime Database. Retrieved from <https://firebase.google.com/docs/>
11. Bird, S., Klein, E., & Loper, E. (2009). Natural Language Processing with Python. O'Reilly Media.
12. Wolf, T., et al. (2020). Transformers: State-of-the-Art Natural Language Processing. EMNLP.

CHAPTER A

Хавсралт

A.1 Системийн тохиргооны жишээ

Туршилтын орчинд дараах үндсэн тохиргоог хэрэглэсэн: Python орчин, Firefox WebDriver, өгөгдлийн сангийн холболт, API токен, скрапингийн delay параметрууд. Эдгээр тохиргоо нь туршилтыг дахин гүйцэтгэхэд шаардлагатай суурь нөхцөлийг бүрдүүлнэ.

A.2 API Endpoint жишээ

Судалгаанд ашигласан гол endpoint-ууд нь /health, /api/v1/scrape, /api/v1/pages, /api/v1/analyze, /api/v1/analyze/advanced, /api/v1/analyze/ai, /api/v1/export/pages зэрэг болно. Эдгээр endpoint нь өгөгдөл цуглуулах, анализ хийх, үр дүн экспортлох үндсэн урсгалыг бүрдүүлсэн.

A.3 Өгөгдлийн сангийн схем

Өгөгдлийн сангийн үндсэн схем нь 'FacebookPost', 'PostComment', 'PostImage' хүснэгтүүд дээр төвлөрсөн. 'FacebookPost' нь үндсэн контент, 'PostComment' нь харилцан үйлдлийн өгөгдөл, 'PostImage' нь дагалдах медиа мэдээллийг хадгалж судалгааны аналитик pipeline-д тэжээл өгдөг.