

ШИНЖЛЭХ УХААН ТЕХНОЛОГИЙН ИХ
СУРГУУЛЬ
МЭДЭЭЛЭЛ, ХОЛБООНЫ ТЕХНОЛОГИЙН СУРГУУЛЬ



Батбилэгийн Анужин

**Тэмдэгт танилтын аргуудын
харьцуулсан судалгаа**

БАКАЛАВРЫН ТӨГСӨЛТИЙН АЖИЛ

Улаанбаатар хот

ШИНЖЛЭХ УХААН ТЕХНОЛОГИЙН ИХ
СУРГУУЛЬ
МЭДЭЭЛЭЛ, ХОЛБООНЫ ТЕХНОЛОГИЙН СУРГУУЛЬ

Мэдээллийн технологийн салбар

ТЭМДЭГТ ТАНИЛТЫН АРГУУДЫН
ХАРЬЦУУЛСАН СУДАЛГАА

Хөтөлбөрийн индекс: D061203

Хөтөлбөр: Мэдээллийн систем

Удирдагч: /...../ Доктор(PhD) Б.Долгорсүрэн

Зөвлөгч: /...../ Магистр Т.Золбоо

Гүйцэтгэгч: /...../ Б.Анужин

Улаанбаатар хот

2022 он

Батлав. Удирдагч:

..... /Доктор(PhD) Б.Долгорсүрэн /

ТӨГСӨЛТИЙН АЖЛЫН ТӨЛӨВЛӨГӨӨ

Сэдэв: "ТЭМДЭГТ ТАНИЛТЫН АРГУУДЫН ХАРЬЦУУЛСАН
СУДАЛГАА "

№	Ажлын бүлэг, хэсгийн нэр	Эзлэх хувь	Дуусах хугацаа
1	Удиртгал	5%	2022-2-22
2	Онолын хэсэг	25%	2022-2-24
3	Судалгааны хэсэг	30%	2022-2-28
4	Төслийн хэсэг	30%	2022
5	Дүгнэлт	10%	2022

Төлөвлөгөөг боловсруулсан оюутан: /Б.Анужин/

Зохиогч эрхийн хамгаалал

Миний бие Б.Анужин, "Тэмдэгт танилтын аргуудын харьцуулсан судалгаа" сэдэвт энэ ажил нь минийх бөгөөд дараахыг нотолж байна. Үүнд:

- Горилогч энэ ажлыг тус сургуулиас боловсролын зэрэг авахаар бүхэлд нь буюу голлон хийсэн болно.
- Энэ ажлын аль нэг хэсгийг тус сургуульд эсвэл өөр байгууллагад боловсролын зэрэг, мэргэшил авахаар өмнө нь илгээсэн бол түүнийгээ тодорхой заасан болно.
- Миний ажилд тусалсан голлох бүх эх үүсвэрт талархаж байна.

Гарын үсэг: _____

Огноо: _____

ШИНЖЛЭХ УХААН ТЕХНОЛОГИЙН ИХ СУРГУУЛЬ
МЭДЭЭЛЭЛ, ХОЛБООНЫ ТЕХНОЛОГИЙН СУРГУУЛЬ

Хураангуй

Тэмдэгт танилтын аргуудын харьцуулсан судалгаа

Б.Анужин

anujin.batbilegg@gmail.com

Түлхүүр үгс: тэмдэгт танилт, тэмдэгт танилтын арга

Энэхүү төслийн хүрээнд тэмдэгт танилтын аргад дүн шинжилгээ хийснээр хэрэгцээтэй шинэ мэдлэг, тэмдэгт таних технологийн аргуудын талаар судлан, гар бичмэл болон хэвлэмэл бичиг баримтын өгөгдөлд танилт хийн, тэмдэг танилтын хувийг таамаглан харьцуулахад оршино.

Ийнхүү сүүлийн үеийн тэмдэгт таних технологийн харьцуулан судалснаар крилл фонтыг таних, танилтын хувийг нэмэгдүүлэх чухал ач холбогдолтой.

Талархал

Энэхүү төслийн ажлыг гүйцэтгэхэд гүн туслалцаа үзүүлсэн удирдагч багш Доктор (Ph.D) Б.Долгорсүрэн, зөвлөх багш магистр Т.Золбоо болон тэнхимийн бүх багш нар, найз нөхөдөдөө гүн талархал илэрхийлье.

Товчилсон үгс

ML	M achine L earning
DL	D ee p L earning
NN	N eural N etwork
ASCII	A merican S tandard C ode for I nformation I nterchange
OCR	O ptical C haracter R ecognition
IWR	I ntelligent W ord R ecognition
ICR	I nn t elligent C haracter R ecognition
OMR	O ptical M ark R ecognition
HMM	H idden M arkov M odels
ANN	A rtificial N eural N etwork
ERP	E nterprise R esource P lanning
API	A pplication P rogramming I nterface

Гарчиг

Зохиогч эрхийн хамгаалал	i
Хураангуй	ii
Талархал	iii
Товчилсон үгс	iv
1 Оршил	1
1.1 Судалгааны ажлын зорилго	1
1.2 Судалгааны ажлын зорилт	1
1.3 Судалгааны ажлын ач холбогдол	1
2 Онолын хэсэг	2
2.1 Машин сургалт	2
2.2 Машин сургалтын арга	4
2.2.1 Удирдлагатай машин сургалт	4
2.2.2 Удирдлагагүй машин сургалт	5
2.2.3 Рэйнфосмэнт машин сургалт	5
2.3 Гүний сургалт	7
2.3.1 Мэдрэлийн сүлжээний сургалт	8
3 Судалгаа хэсэг	9
3.1 Тэмдэгт танилтын төрлийн судалгаа	9
3.1.1 Оптик Тэмдэгт Таних(Optical Character Recognition) . .	10
3.1.2 Ухаалаг Үг Таних(Intelligent Word Recognition)	11
3.1.3 Ухаалаг Тэмдэгт Таних(Intelligent Character Recognition)	12
3.1.4 Оптик Тэмдэглэгээг Таних(Optical Mark Recognition) .	12
3.2 Оптик тэмдэгт таних үе шат, алхмууд	13
3.3 Оптик тэмдэгт таних програм хангамжийн судалгаа	16
3.4 Тэмдэгт танилтын алгоритмууд	20
3.4.1 Загвар тааруулах	21
3.4.2 Fuzzy logic	22
3.4.3 Шинж чанарыг задлах	23
3.5 Оптик тэмдэгт таних техникүүд	25
3.5.1 OCRopus	25
3.5.2 Kraken	26
3.5.3 Calamari OCR	28
3.5.4 Keras OCR	28
3.5.5 Tesseract OCR	29

3.5.6	EasyOCR	29
3.5.7	Техникийн харьцуулалтууд	30
4	Туршилт үр дүн	32
4.1	Оптик тэмдэгт таних туршилт	32
4.1.1	EasyOCR ашигласан туршилт	32
4.1.2	Орчин бэлдэх	32
4.1.3	Монгол хэлний өгөгдөл бэлтгэх	35
5	Дүгнэлт	37
5.1	Дүгнэлт	37
5.2	Ашигласан материал, ном зүй	38

Зургийн жагсаалт

2.1	Машин сургалт	2
2.2	Машин сургалтын төрлүүд	4
2.3	Удирдлагатай(supervised) машин сургалт	5
2.4	Удирдлагагүй(unsupervised) машин сургалт	5
2.5	Рэйнфосмэнт(reinforcement) машин сургалт	6
2.6	Машин сургалт ба гүний сургалтын ялгаа	7
2.7	Сургалтын гүйцэтгэлийн чадвар	8
3.1	Рэй Курцвейл 1970-аад оны сүүл үе. Харааны бэрхшээлтэй болон суралцах боломжгүй хүмүүст зориулсан уншдаг машин-тайгаа.	9
3.2	Тэмдэгт таних	13
3.3	Тэмдэгтийн холбогдсон шугамуудыг таних	14
3.4	Тэмдэгт таних	14
3.5	Тэмдэгт дүрсийг санах	15
3.6	https://nanonets.com	16
3.7	https://www.abbyy.com	17
3.8	https://www.ibm.com/products/data-capture-and-imaging	18
3.9	https://cloud.google.com/document-ai	19
3.10	Загвар тааруулах алгоритмын ажлын урсгалын диаграм	21
3.11	Загвар тааруулах томьёо	22
3.12	Fuzzy logic ангилагчийг ашиглан гарсан үр дүн	23
3.13	Хүрээ бүхий контурын чиглэл ба гулзайлтын онцлог	24
3.14	Солбцох болон зайны(crossings and distances) жишээ	25
3.15	OCRopus системийн бүрдүүлдэг урсгалын диаграм	26
3.16	Kraken	27
3.17	Tesseract системийн архитектур	29
3.18	Tesseract системийн ажиллагаа	29
3.19	EasyOCR-н фреймворк	30
3.20	Дэмждэг зургийн өртгөтгөл	30
3.21	Алдааний түвшин болон GPU, CPU дээрх зураг танилтын хугацаа	30
3.22	500 зураг таньсан жишээ	31
4.1	EasyOCR идэвхжүүлэх	33
4.2	pytorch суулгах	33
4.3	pip ашиглан easyocr суулгах	34
4.4	pip ашиглан easyocr суулгах	34
4.5	Монгол хэлний загвар танилтын загвар	35
4.6		35

4.7	Туршилт	36
4.8	Туршилтад ашигласан зургууд	36
4.9	Туршилтын харьцуулалт	36

Хүснэгтийн жагсаалт

БҮЛЭГ 1

Оршил

1.1 Судалгааны ажлын зорилго

Тэмдэгт танилтын аргуудын талаар судлан танилтын аргыг харьцуулан судалж дүн шинжилгээ хийж зорилготой. Кирилл фонт таних арга, гар бичмэл дээрх боломжит хэрэгжүүлэлт, танил, танилтын үе шатууд, алгоритмын ажиллагаа, танилтын хувийг тооцоолон туршилт хийнэ.

1.2 Судалгааны ажлын зорилт

- Хиймэл оюун ба машин сургалтын тухай ойлголтын талаар судлах
- Тэмдэгт танилт болон түүний аргуудын талаар судлах
- Тэмдэг танилтад түгээмэл ашигладаг алгоритмыг судлах
- Тэмдэгт танилтын техникүүдийг судлах
- Шаардлагатай өгөгдлийг судлах, бэлтгэх
- Танилтын техникийн туршилт хийн монгол үсэг танилтыг зураг ашиглан туршиж харьцуулалт хийх
- Ач холбогдол бүхий шинэ мэдээлэл, мэдлэг гаргаж авах

1.3 Судалгааны ажлын ач холбогдол


Тэмдэг танилтын аргыг кирилл фонт танихад ашигласнаар цаасан бичиг баримтыг дижитал хэлбэрт шилжүүлэн шаардлагатай үед хурдан мэдээллийн хайлт хийх, засварлах, хадгалах боломжтой.

БҮЛЭГ 2

Онолын хэсэг

2.1 Машин сургалт

Машин сургалт нь хиймэл оюун ухааны нэг хэсэг бөгөөд өгөгдөл болон мэдээллийг тусгай зааварчилгаа ашиглалгүйгээр алгоритмууд болон статистик загварууд ашиглан тухайн өгөгдлийн нийтлэг шинж чанар дээр үндэслэн судалдаг, суралцдаг үйл ажиллагаа юм. 1959 онд Артур Самуэл Машин сургалт гэдэг нэр томъёог анх нэвтрүүлсэн байдаг. Машин сургалтыг өгөгдлөөс автоматаар суралцах, туршлагын үг дүнг сайжруулах, аливаа зүйлийг урьдчилан таамаглах боломж гэж үздэг. Сургалтын өгөгдлийг түүврийн тусламжтайгаар машин сурах алгоритмууд нь тодорхой програмчлалгүйгээр урьдчилан таамаглах эсвэл шийдвэр гаргахад тусалдаг математик загварыг бий болгодог.[1]



Зураг 2.1: Машин сургалт

Машин сургалтын 3 чухал алхам байдаг. Үүнд,

1. Өгөгдөл түүний чухал шинж чанараар задлах нь (Data, feature extraction) машин сургалтын хамгийн эхний алхам бөгөөд өгөгдөлгүйгээр машин сургалтыг явуулах боломжгүй. Өгөгдлийн шинж чанаруудыг задлахын тулд дараах асуултуудыг авч үзэх хэрэгтэй.

- Ямар өгөгдөл ашиглах вэ?
- Хэр хэмжээний өгөгдөл хэрэгтэй вэ?
- Ямар төрлийн өгөгдлийг цуглуулах вэ?
- Өгөгдлийн хэв маяг онцлог нь?
- Өгөгдлөөс ямар онцлог шинж чанаруудыг хэрхэн олж илрүүлэх вэ?

Өгөгдлийн онцлог шинж чанарууд нь загварыг сургахад ашиглах болох өгөгдлийн багц дахь хэв шинжүүд юм. Шинж чанарууд нь урьдчилан таамаглах эсвэл шийдвэр гаргахад хамгийн их хувь нэмэр оруулдаг бөгөөд машин сургалтын загварыг нарийвчлал үр дүнд шууд нөлөөлдөг учраас машин сургалтын ашиглан өгөгдлийг загварчлахын тулд өгөгдөл сонголт, түүний

шинж чанаруудыг зөв сонгон илрүүлэх нь хамгийн чухал алхам юм. Өгөгдлийн шинж чанаруудыг олж илрүүлснээр:


- Хэрэглэгдэхгүй өгөгдлийг арилгах
- Хэт их тохирох байдлыг багасгах
- Машин сургалтын нарийвчлалыг сайжруулах боломжууд бий болно.

2. Өгөгдлийг загварчлах (Data modeling) үйл явц гэдэг нь шинж чанаруудаас таамаглаж буй утга буюу хаяг (label) эсвэл зорилтот (target) хувьсагчдыг урьдчилан таамаглах, бизнесийн хэрэгцээнд нийцүүлэн тохируулах, өгөгдлийг баталгаажуулахад ашиглах машин сургалтын алгоритмуудыг сургахыг хэлнэ. Загварчлалын үр дүн нь шинэ өгөгдөл дээр таамаглал дэвшүүлж дүгнэлт гаргахад ашиглаж болох сургасан загвар юм. Машин сургалтын зорилго нь сургалтын өгөгдлийг сайн хийдэг загвар биш, харин бизнесийн хэрэгцээг хангаж, шууд өгөгдөлд ашиглах боломжтойг харуулдаг загвар юм.

3. Алдааны функц (Error function) нь сургалтын сүлжээнд алдааг бодит гаралт болон урьдчилан таамаглаж буй үр дүнгийн зөрүүгээр тооцдог. Алдагдлын янз бүрийн функцүүд нь ижил таамаглалд өөр өөр алдаа гаргадаг бөгөөд ингэснээр загварын гүйцэтгэлд ихээхэн нөлөө үзүүлдэг. Оновчлол (Optimization) гэдэг нь функцийн хамгийн дээд буюу доод төвшний үнэлгээний үр дүнд бий болох зорилтот функцийн оролтын багцыг олох явдал юм. Энэ нь оролтын параметр эсвэл аргументыг олох процесс юм. Машин сурахад тулгардаг хамгийн нийтлэг оновчлолын асуудал бол функцийн тасралтгүй оновчлол бөгөөд функцэд оруулах оролтын аргууд нь бодит утгаараа тоон утгууд байдаг. Функцээс гарах үр дүн бол оролтын утгын бодит үнэлгээ юм.

2.2 Машин сургалтын арга

Машин сургалтыг дотор нь удирдлагатай(supervised), удирдлагагүй(unsupervised) болон reinforcement сургалт гэж ангилдаг. Ерөнхий процесс нь өгөгдлийг цуглуулж зохион байгуулаад урьдчилан боловсруулна, цэвэрлэнэ, дүрслэн үзүүлнэ, суурь хэмжигдэхүүн(baseline) бий болгоно, моделио сонгоод, алдагдлыг тооцож, регуляц-ийг тодорхойлно, оптимаци хийж оновчтой хайперпараметруудийг хайж гүйцэтгэлийг шинжилж, алдааг тодорхойлоод шаардлагатай бол процессуудыг модель сонгохоос эхлээд дахин давтана. Өгөгдлийн олон төрлүүд болох зураг, текст, аудио, кредит картын гүйгээний мэдээлэл зэргийг оролтоор авч суралцдаг.[2]




ЗУРАГ 2.2: Машин сургалтын төрлүүд

2.2.1 Удирдлагатай машин сургалт

Удирдлагатай сургалт нь машин сургалт болон хиймэл оюун ухааны дэд ангилал юм. Энэ нь өгөгдлийг ангилах эсвэл үр дүнг үнэн зөв урьдчилан таамаглах алгоритмуудыг сургах зорилгоор таамаглаж буй утга буюу хаяг(label) өгөгдлийн багцыг ашигласнаар тодорхойлогддог. Удирдлагатай сургалтад оролт-гаралт үндэслэн олотыг гаралтад буулгах функцийг сурч авахыг хэлнэ. Спамыг имэйлийг тусдаа хавтсанд ангилах гэх мэт бодит янз бүрийн асуудлыг шийдвэрлэхэд тусалдаг. [3]


Удирдлагатай сургалтын аргачлалыг регресс ба ангиллын алгоритм гэж ерөнхийд нь хувааж болно. Үүнд: Логистик регресс, Шийдвэрийн мод, Санамсаргүй ой, Бейсийн алгоритмууд орно.



ЗУРАГ 2.3: Удирдлагатай(supervised) машин сургалт

2.2.2 Удирдлагагүй машин сургалт

Удирдлагатай сургалтаас ялгаатай нь удирдлагагүй сургалт нь хаяг (label) эсвэл зорилтот (target) хувьсагч байхгүйгээр оролтын өгөгдлөөс дүгнэлт гаргах, загвар олоход ашигладаг. Удирдлагагүй сургалт нь машинд зөвхөн оролтын мэдээллийг өгөх, машин өөрөө тухайн өгөгдлөөс бүтцийг нь таньж сурах процесс юм. Хяналтгүй сургалт нь бүлэглэлт хийх (Clustering) болон хэмжээсийг багасгах (Data reduction) гэсэн үндсэн 2 төрөлтэй.



ЗУРАГ 2.4: Удирдлагагүй(unsupervised) машин сургалт

2.2.3 Рэйнфосмент машин сургалт

Рэйнфосмент сургалт нь хүрээлэн буй орчинтой харилцан үйлчлэхэд суурилсан зорилгод чиглэсэн сургалт юм. Рэйнфосмент сургалт нь жинхэнэ хиймэл оюун ухааны найдвар гэж ярьдаг. Эцсийн үр дүн нь тоон онооны дохиог хамгийн их байлгах явдал юм. Суралцагсдад ямар арга хэмжээ авахаа заагаагүй харин үүний оронд аль үйлдэл нь хамгийн их оноо авчрахыг олж мэдэх ёстой. Үүнийг энгийн жишээн дээр ойлгоцгооё. Хүүхэд алхаж сурч байгаа жишээг авч үзье. Хүүхдийн ажиглах хамгийн эхний зүйл бол таны хэрхэн явж байгааг анзаарах явдал юм. Явган алхахын тулд та алхам алхмаар хоёр хөлөөрөө явдаг. Энэ ойлголтыг ойлгосноор хүүхэд таныг давтахыг хичээдэг. Энэ нь нэг төлөвөөс нөгөө төлөв рүү шилжихийг хичээдэг.




ЗУРАГ 2.5: Рэйнфосмэнт(reinforcement) машин сургалт

Хүүхэд даалгаврын дэд модулийг биелүүлснээр шагнал авна, алхаж чадахгүй үедээ ямар ч шагнал авахгүй. Энэ бол рэйнфосмэнт сургалтын асуудлын хялбаршуулсан тодорхойлолт юм.[4]

2.3 Гүний сургалт

Машин сургалт нь мэдээллийн онцлог шинж чанаруудыг олборлоод ангилдаг бол гүн сургалт нь мэдээллийн онцлог шинж чанаруудыг олборлогчгүйгээр шууд ангилж болдог. Учир нь гүн сургалт нь нейронуудын тусламжтайгаар өгөгдлийн онцлог шинж чанаруудыг ангилахдаа хамтад нь тооцоолж тодорхойлдог. Харин машин сургах нь өгөгдлийн онцлог шинжүүдийг тодорхойлохдоо хүнд математикийн тооцоолол ашигладаг ч үр дүн нь баталгаагүй байдаг. Гүн сургалт нь маш их хэмжээний сургалтын өгөгдөл болон тооцооллын хүчин чадлыг шаарддаг.



ЗУРАГ 2.6: Машин сургалт ба гүний сургалтын ялгаа

Гүний сургалт нь дараах чиглэлээр өргөн хэрэглэгдэж байна. Үүнд:


- Эрүүл мэндийн үйлчилгээ
- Компьютерийн алсын хараа ба хэв загварыг таних
- Компьютер тоглоои, робот ба өөрөө явагч машин
- Дуугаар идэвхжүүлсэн ухаалаг утаснууд
- Зар сурталчилгаа
- Байгалийн гамшгийг урьдчилан таамагла
- Санхүү

2.3.1 Мэдрэлийн сүлжээний сургалт

Мэдрэлийн сүлжээг 1970-аад рны үед зрхион бүтээсэн боловч сүүлийн үеүүдэд тооцоолох чадвар нь нэмэгдэж байгаагийн хэрээр маш их алдартай болсон.

Мэдрэлийн сүлжээ нь хүний тархи шиг ажиллахад зориулагдсан систем юм. Хүний мэдээллийн боловсруулалт нь хоорондоо холбогдсон олон тэрбум харилцан үйлчлэлээр дамжуулан бусад нейронуудад дохио илгээдэг. Үүнтэй адил мэдрэлийн сүлжээ нь хүний тархинд байдаг хиймэл мэдрэлийн эсүүдийн сүлжээ бөгөөд дүрс таних гэх мэт хиймэл оюун ухааны асуудлыг шийдвэрлэхэд зориулагдсан байдаг.

Сүүлийн үед мэдрэлийн сүлжээ нь патерн таних, таамаглах, шинжилгээний асуудлуудад гол түлхэлтийг авчирч байна. Зургуудыг сегментлэх, таних, хөрөнгийн зах зээлийг урьдчилан таамаглах гээд бүхий л салбарт ашиглагдаж байна.



ЗУРАГ 2.7: Сургалтын гүйцэтгэлийн чадвар

БҮЛЭГ 3

Судалгаа хэсэг

3.1 Тэмдэгт танилтын төрлийн судалгаа

Оптик тэмдэгт таних (OCR) нь хэвлэсэн эсвэл гараар бичигдсэн сканнердсан баримт бичгүүдийг компьютер таних ASCII тэмдэгт болгон хувиргах үйл явц юм.[5]

1974 онд Рэй Курцвейл Computer Products, Inc-ийг үүсгэн байгуулсан бөгөөд түүний omni-font оптик тэмдэгт таних (OCR) бүтээгдэхүүн нь бараг ямар ч фонтоор хэвлэсэн текстийг таньж чаддаг байв. Тэрээр энэ технологи нь харааны бэрхшээлтэй хүмүүст зориулсан машин сургалтын төхөөрөмж байх болно гэж үзээд текстийг ярианы форматаар чангаар унших боломжтой унших машин бүтээжээ. OCR технологи нь 1990-ээд оны эхээр түүхэн баримтуудыг дижитал хэлбэрт шилжүүлэх явцад түгээмэл хэрэглэгдэх болсон. Түүнээс хойш технологи нь хэд хэдэн сайжруулалтад орсон.



ЗУРАГ 3.1: Рэй Курцвейл 1970-аад оны сүүл үе. Харааны бэрхшээлтэй болон суралцах боломжгүй хүмүүст зориулсан уншдаг машинтайгаа.

Өнөөгийн шийдлүүд нь бараг төгс OCR нарийвчлалыг хүргэх чадвартай. Баримт бичиг боловсруулах нарийн төвөгтэй ажлын урсгалыг автоматжуулахад дэвшилтэт аргуудыг ашигладаг. OCR технологи гарахаас өмнө баримт бичгийг дижитал хэлбэрт оруулах цорын ганц сонголт бол текстийг гараар дахин бичих байсан. Энэ нь цаг хугацаа шаардсан, бичгийн алдаатай байсан. Өнөөдөр OCR үйлчилгээг олон нийтэд өргөнөөр ашиглах боломжтой болсон.[6] Жишээлбэл, Google Cloud Vision OCR нь таны ухаалаг утсан дээрх баримтуудыг сканнердаж, хадгалахад ашиглагддаг.

3.1.1 Оптик Тэмдэгт Таних(Optical Character Recognition)

Оптик тэмдэгт таних (OCR) технологи нь автоматжуулсан өгөгдөл олборлох(extraction), хадгалах чадварыг ашиглан цаг хугацаа, зардал болон бусад нөөцийг хэмнэдэг үр үнтэй бизнесийн процесс юм.

Оптик тэмдэгт таних (OCR)-г заримдаа текст таних гэж нэрлэгддэг. OCR програм нь сканнердсан баримт бичиг, зураг, pdf файлуудаас өгөгдлийг гаргаж ашигладаг. OCR программ хангамж нь зураг дээрх үсгүүдийг ялгаж, үг болгон оруулаад дараа нь үгсийг өгүүлбэрт оруулдаг.

OCR-ийн тусламжтайгаар дижитал зураг дээрх оптик хэв маягийг үсэг, тоон тэмдэгтүүдтэй хэрхэн харьцаж байгаагаас хамааран ангилдаг. Энэ нь баримт бичгийн хэвлэмэл хуулбар, PDF файлаас эхлээд JPG болон ном хүртэл бараг бүх зүйлийг дижитал болгож болно гэсэн үг юм.

OCR програм хангамж нь хиймэл оюун ухааны (AI) давуу талыг ашиглан тэмдэгт таних (ICR) илүү дэвшилтэт аргууд, тухайлбал ямар хэл дээр бичигдсэн, гар бичгийн хэв маягийг тодорхойлох боломжийг олгодог. OCR процесс нь хууль эрх зүйн болон түүхэн баримт бичгүүдийг PDF баримт болгон хувиргахад ихэвчлэн ашиглагддаг бөгөөд ингэснээр хэрэглэгчид бичиг баримтыг засварлах, бүтэцлэх, хайх боломжтой. OCR-ийг ихээр ашигладаг салбарууд,

- Банкууд
- Эрүүл мэндийн байгууллагууд
- Хүний нөөц
- Даатгалын компаниуд
- Хуулийн фирмүүд
- Жижиглэн худалдаа
- Аялал жуулчлал

3.1.2 Ухаалаг Үг Таних(Intelligent Word Recognition)

Энэ нь зөвхөн хэвлэсэн болон гараар бичсэн өгөгдлийг таньж, задлаад зогсохгүй бичмэлийг ч таньдаг. ICR программ хангамж нь үсгийн түвшинд таних ба бүрэн хэллэг, үгсийг агуулдаг. Энэ нь бүтэцгүй мэдээлэл авах чадвартай бөгөөд ICR-тэй харьцуулахад илүү нарийвчилсан байдаг.

IWR нь гараар бичсэн үгсийг таних. IWR нь хиймэл оюун ухааныг ашиглан баримт бичигт байгаа үгсийг дан тэмдэгтүүдээс ялгаатай нь бүхэлд нь таньдаг. Энэ нь үгийн шинж чанарыг тэмдэгтээр таньдаг OCR-аас ялгаатай юм. Жишээлбэл, OCR ашиглан "хүү" гэсэн үгийг задлахад систем нь "х", "ү", "ү" таних болно. IWR нь хээ таних болон янз бүрийн алгоритм дээр үндэслэн "хүү" гэдэг үгийг бүхэлд нь гаргаж авахын тулд үсгүүдийг толь бичигт тохируулна.

IWR файлуудын тусламжтайгаар тухайн баримт бичгийн түлхүүр үгийн дагуу хайлт хийх боломжтой. Жишээлбэл, өдөрт хэдэн зуун өргөдөл хүлээн авдаг Хүний нөөцийн агентлагийг авч үзье. Эдгээрийн ихэнх нь гараар бичсэн маягтуудыг агуулж болно. IWR технологийн тусламжтайгаар маягтуудыг сканердаж, бүрэн дижитал хэлбэрт шилжүүлснээр биет файлын шүүгээнүүдээр хайхад тоо томшгүй олон цаг зарцуулалгүйгээр бие даасан програмуудыг хайхад хялбар болно. Энэ нь цаг хугацаа, зардлыг ихээхэн хэмнэх боломжтой юм. Энэ төрлийн технологи нь цаасгүй оффис руу шилжихийг хүсч буй компаниудад хялбар бөгөөд тохиромжтой болгодог.

Гар бичмэлийг таних асуудлыг шийдэх анхны арга барилд Нууц Марковын загвар (НММ), SVM гэх мэт Машин сургалтын аргуудыг ашигласан. Анхны текстийг урьдчилан боловсруулсны дараа гогцоо, гулзайхын цэг, харьцаа гэх мэт гол мэдээллийг тодорхойлохын тулд онцлог задлах ажлыг гүйцэтгэдэг. хувь хүний шинж чанартай. Эдгээр үүсгэсэн функцуудыг одоо НММ гэж ангилагч руу нийлүүлж, үр дүнг олж авдаг. Машин сургалтын загваруудын гүйцэтгэл нь гарын авлагын онцлогийг задлах үе шат, суралцах чадвар нь хязгаарлагдмал зэргээс шалтгаалан нэлээд хязгаарлагдмал байдаг. Онцлогийг олборлох алхам нь хэл бүрт өөр өөр байдаг тул өргөтгөх боломжгүй. Гүнний сургалттай болсноор гар бичмэлийг таних нарийвчлалд асар их ахиц гарсан.

3.1.3 Ухаалаг Тэмдэгт Таних(Intelligent Character Recognition)

ICR нь OCR өргөтгөсөн технологи юм. OCR нь гараар хэвлэсэн тэмдэгтүүдэд анхаарлаа төвлөрүүлдэг бол ICR нь текстийг таних, нарийвчлалыг сайжруулахын тулд гар бичмэлийн өөр өөр хэв маяг, фонтыг компьютерийн системээр сурах боломжийг олгодог.

ICR программ хангамж нь зургийн файлаас гар бичмэлийг авдаг. Энэ нь хэвлэсэн тэмдэгтүүдийг авдаг OCR технологийн дэвшилтэт хувилбар юм. Технологи нь илүү нарийвчлалтай, таних хурдыг өгөхийн тулд сайжруулсаар байгаа тул ICR нь өөрчлөлтийн үе шатанд байна. Энэ талбар дахь өөрчлөлт, тохируулга нь тогтмол байдаг бөгөөд энэ нь цаг хугацааны явцад технологийг илүү найдвартай болгох боломжийг бүрдүүлдэг.

Үнэн хэрэгтээ OCR-тэй харьцуулбал ICR-ийн үр дүн зөв биш хэвээр байна гэж хэлж болно. Шалтгаан нь одоо байгаа ICR программ хангамж нь хиймэл оюун ухааны хөгжүүлсэн мэдрэлийн сүлжээг байнга сурч байгаа юм. Өгөгдөл хэдий чинээ их байх тусам ICR програм хангамж нь гараар бичсэн баримт бичгүүдийг сурч, боловсруулах боломжтой болно.

ICR нь хиймэл оюун ухаанд суурилсан мэдрэлийн сүлжээний загварыг хөгжүүлснээр гар бичмэлийн шинэ хэв маяг, фонтуудыг ойлгуулах боломжтой бөгөөд ингэснээр систем нь шинэ баримт бичгийн хэв маяг, фонт бүрийг өөрөө сурах боломжийг олгодог. Энэ нь загвар нь шинэ төрлийн баримт бичиг сурах бүрт ICR програм хангамж нь мэдээллийн санг сайжруулдаг бөгөөд энэ нь эцсийн дүндээ програм хангамжид гар бичмэлийг өндөр нарийвчлалтайгаар үр дүнтэй урьдчилан таамаглахад тусалдаг гэсэн үг юм. Хиймэл мэдрэлийн сүлжээ (ANN) загварын шинэ өгөгдөл бүрд шинэ болон өмнөх өгөгдлийг гар бичмэл, фонт, хэв маяг гэх мэтийг урьдчилан таамаглахад ашигладаг.

3.1.4 Оптик Тэмдэглэгээг Таних(Optical Mark Recognition)

OMR нь баримт дээрх тэмдэглэгээ, хэв маягийг таних замаар хүний оруулсан өгөгдлийг цуглуулах арга юм. Үүний хамгийн том жишээ бол элсэлтийн ерөнхий шалгалтын шоглоом дүгнэх, сонгуулийн санал хураалтад ашигладаг билээ.

3.2 Оптик тэмдэгт таних үе шат, алхмууд

Оптик тэмдэгт таних (OCR) нь баримт бичгийн физик хэлбэрийг боловсруулахын тулд сканнер ашигладаг. Бүх хуудсыг хуулсаны дараа OCR программ хангамж нь баримтыг хоёр өнгийн эсвэл хар цагаан болгон хувиргадаг. Сканнердсан зураг эсвэл битмапын цайвар, бараан хэсэгт нь шинжилж, бараан хэсгийг таних шаардлагатай тэмдэгтүүд, цайвар хэсгийг нь дэвсгэр гэж тодорхойлоод үсэг эсвэл тоог цифрүүдийг олохын тулд бараан хэсгийг нь боловсруулдаг. Дараа нь загвар таних эсвэл онцлогийг таних гэсэн хоёр алгоритмын аль нэгийг ашиглан тэмдэгтүүдийг тодорхойлно.



ЗУРАГ 3.2: Тэмдэгт таних

OCR нь сканнердсан баримт бичигт тэмдэгтүүдийг танихын тулд тодорхой үсэг эсвэл тооны онцлогтой холбоотой дүрмийг хэрэглэх үедээ онцлог шинж чанарыг нь илрүүлдэг. Онцлогууд нь тэмдэгт дэх өнцгийн шугам, хөндлөн шугам эсвэл муруйн тоог агуулдаг. Жишээлбэл, "А" том үсгийг дундуур нь хөндлөн шугамтай нийлсэн хоёр диагональ шугам хэлбэрээр хадгалдаг. Тэмдэгтийг таних үед түүнийг компьютерийн системүүд дараагийн залруулга хийхэд ашигладаг ASCII код (Мэдээлэл солилцох Америкийн стандарт код) болгон хувиргадаг.

Оптик тэмдэгт таних алхмууд:

1. Зургаас тэмдэгтийн шугамыг гаргаж авах,
2. Тэмдэгтийн дүрсийг санахын тулд Convolutional Neural Network (ConvNet) байгуулах,
3. Convolutional Neural Network(ConvNet) загварыг ачааллах
4. Convolutional Neural Network-ийн тэмдэгтүүдийн таамаглалыг нэгтгэх

1.Зураг баримт цуглуулах

Холбогдсон шугамуудыг бүх үргэлжилсэн цэгүүдийг шугамын дагуу холбосон муруй гэж энгийнээр тайлбарлаж болно. Холбогдсон шугамууд нь дүрсийг шинжлэх, объектыг илрүүлэх, танихад хэрэгтэй юм. Энэ нь зургийг сегментлэх арга юм.

As he had expected, Mrs. Dursley looked shocked and angry. After all, they normally pretended she didn't have a sister.

"No," she said sharply. "Why?"

"Funny stuff on the news," Mr. Dursley mumbled. "Owls... shooting stars... and there were a lot of funny-looking people in town today..."

"So?" snapped Mrs. Dursley.

"Well, I just thought... maybe... it was something to do with... you know... her crowd."

ЗУРАГ 3.3: Тэмдэгтийн холбогдсон шугамуудыг таних

Гарган авсан текстийн тэмдэгтүүд нь түүнтэй холбоотой эх тэмдэгтийн нэрээр хаяглагдсан байх ёстой. Энд дагаж мөрддөг нэршлийн дүрэм бол файлын нэрний сүүлчийн үсэг нь зургийн өгөгдлийг урьдчилан боловсруулахад зориулагдсан тэмдэгттэй холбоотой нэр байх ёстой.


w 1-0-lw	5 1-2-ls	e 1-2-le	1 1-3-ll	4 1-4-l	5 1-5-l	g 1-8-lg
r 1-10-lr	a 1-11-la	a 1-12-la	s 1-13-ls	s 1-14-ls	n 1-15-ln	e 1-16-le
e 1-18-le	r 1-19-lr	p 1-20-lp	e 1-21-le	r 1-22-lr	o 1-23-lo	m 1-24-lm
n 1-26-ln	i 1-27-li	p 1-28-lp	o 1-29-lo	p 1-30-lp	a 1-31-la	t 1-32-lt

ЗУРАГ 3.4: Тэмдэгт таних

Хэд хэдэн урьдчилсан боловсруулалтын алхмуудыг хийдэг. Сканнердах процессын үр дүнд үүссэн зураг нь тодорхой хэмжээний бага нягтралыг агуулж болно Smoothing гэдэг нь дүүргэх(filling), сийрэгжүүлэх(thinning) гэсэн утгатай. Дүүргэх(filling) нь дижитал тэмдэгтүүдийн жижиг эвдрэл, ду-тагдал, цоорхойг арилгадаг бол сийрэгжүүлэх(thinning) нь шугамын өргө-нийг багасга даг.

2. Тэмдэгтийн дүрсийг санахын тулд Convolutional Neural Network (ConvNet) байгуулах

Зургийг санахад ашигладаг 28×28 давхаргын хасахад үлдсэн хариу үйлдэл бүхий 8 давхарга Convolution Network.



ЗУРАГ 3.5: Тэмдэгт дүрсийг санах

1-р загвар нь дүрийн ангиллын softmax ангилал бүхий зургуудыг урьдчилан таамаглахын тулд шууд зураг дээр сургана.

2-р загвар нь урьдчилан таамаглагчийн өмнөх давхаргатай ижил загвар бөгөөд тодорхой хавтгайрсан нейронуудын суулгацыг тооцоолох болно.

3. Convolutional Neural Network(ConvNet) загварыг ачааллах

Тэмдэгтийн оптик таних сүүлчийн алхам нь дүрсийг үгтэй холбоотой холбосон шугам, үсгийн холбосон шугам болгон урьдчилан боловсруулах, дараа нь зураг дээрх үсэг, үгтэй холбоотой холбосон шугамын дагуу урьдчилан таамаглах, нэгтгэх явдал юм.


Загварыг сургасны дараа бид урьдчилан бэлтгэсэн Оптик тэмдэгт таних загварыг хадгалж, ачаалж болно.

4. Convolutional Neural Network-ийн тэмдэгтүүдийн таамаглалыг нэгтгэх

Урьдчилан таамаглалыг нэгтгэх нь зураг дээрх үгтэй холбоотой шугамын үг бүрт тодорхой ID оноох, бүх таамаглалыг тодорхой үгтэй холбоотой холбогдсон шугам, үсэгтэй холбоотой үгийн эрэмбэлэгдсэн цувралд нэгтгэх зэрэг орно.

3.3 Оптик тэмдэгт таних програм хангамжийн судалгаа

Nanonets



ЗУРАГ 3.6: <https://nanonets.com>


Nanonet-ийн хиймэл оюун ухаанд суурилсан OCR программ хангамжийг ашиглан гар аргаар өгөгдөл оруулах ажлыг автоматжуулах. Баримт бичгүүдээс өгөгдлийг шууд авах. Эргэлтийн хугацааг багасгаж, гар ажиллагаатай холбоотой хүчин чармайлтыг арилгана. Давуу тал:

- Орчин үеийн UI
- Их хэмжээний баримт бичгийг зохицуулдаг
- Үнийн хувьд боломжийн
- Ашиглахад хялбар
- Өгөгдлийг танин мэдэхүйн аргаар олж авах - энэ нь хамгийн бага хөндлөнгийн оролцоог бий болгодог
- Дотоодын хөгжүүлэгчдийн баг шаардлагагүй
- Алгоритм/загваруудыг сургах/дахин сургах боломжтой
- Маш сайн баримт бичиг, дэмжлэг
- Маш олон тохируулгын сонголтууд
- Интеграцийн сонголтуудын өргөн сонголт
- Англи бус эсвэл олон хэл дээр ажилладаг
- Бараг л дараах боловсруулалт хийх шаардлагагүй
- Нягтлан бодох бүртгэлийн олон программтай 2 талын саадгүй нэгдэл
- Хөгжүүлэгчдэд зориулсан гайхалтай API

Сул тал:

- Маш их хэмжээний огцом өсөлтийг даван туулах боломжгүй
- Хүснэгт авах UI илүү сайн байж болно

ABBYY Flexicapture



ЗУРАГ 3.7: <https://www.abbyy.com>


FlexiCapture нь аливаа бүтэц, хэл, агуулгын баримт бичгийг ашиглах боломжтой, хүртээмжтэй бизнест бэлэн өгөгдөл болгон автоматаар хувиргадаг тогтвортой, өргөтгөх боломжтой баримт бичгийн дүрслэл, өгөгдөл олборлох програм хангамж юм. Давуу тал:

- Зургийг маш сайн таньдаг
- Системд хэвлэсэн үр дүнг хадгалахад хялбар
- ERP системүүдтэй сайн уялдаатай
- Баримт бичгээс өгөгдөл олборлолтыг автоматжуулах

Сул тал:

- Анхны тохиргоо нь хэцүү, төвөгтэй байж болно
- Бэлэн загвар байхгүй
- Тохируулахад хэцүү
- Бага нарийвчлалтай зураг/баримт бичгийн нарийвчлал бага
- Алгасах ёстой зүйлүүдэд ч гэсэн мөрийн алдааны мэдэгдлүүд гарч ирдэг
- RESTful API нь үндсэн хувилбарт байхгүй

IBM Datacap



ЗУРАГ 3.8: <https://www.ibm.com/products/data-capture-and-imaging>

Datacap нь бизнесийн баримт бичгүүдээс чухал мэдээллийг олж авах, та-
них, ангилах ажлыг хялбаршуулдаг. Datacap нь хүчирхэг OCR машинтай,
олон функцтэй, мөн өөрчлөх боломжтой дүрэмтэй. Энэ нь сканнер, хөдөл-
гөөнт төхөөрөмж, олон үйлдэлт нэмэлт төхөөрөмж, факс зэрэг олон сувгаар
ажилладаг. Давуу тал:


- Өгөгдөл барихад төвөгтэй програмуудыг тохируулдаг
- Сканнердах механизм
- Ашиглахад хялбар

Сул тал:

- Маш бага онлайн дэмжлэг
- UI нь илүү ойлгомжтой байж болох юм
- Тохируулга нь төвөгтэй
- Удаан
- Хугацаа шаарддаг

Google Document AI

Google Cloud AI иж бүрдэл дэх шийдлүүдийн нэг болох Document AI (DocAI) нь баримт бичгийн доторх мэдээллийг автоматаар ангилах, задлах, баяжуулах, ойлголтыг нээхэд машин сургалтыг ашигладаг баримт бичиг боловсруулах консол юм.



ЗУРАГ 3.9: <https://cloud.google.com/document-ai>

Давуу тал:

- Тохируулахад хялбар
- Google-н бусад үйлчилгээнүүдтэй маш сайн нэгдсэн
- Мэдээлэл хадгалах
- Хурд

Сул тал:

- AI модулиудад зохих баримт бичиг байхгүй
- Python болон бусад кодчиллын хэлэнд тохиромжгүй
- Хуучирсан API баримт бичиг
- Үнэтэй

Adobe Acrobat DC

Adobe нь OCR функц бүхий цогц PDF засварлагчаар хангадаг. Давуу тал:

- Тогтвортой байдал / нийцтэй байдал.
- Ашиглахад хялбар

Сул тал:


- Үнэтэй
- Системд ачаалал ихтэй
- Хатуу диск дээр маш их зай эзэлнэ
- Sharepoint эсвэл Dropbox зэрэг үйлчилгээнүүдийг нэгтгэхэд хэцүү
- Adobe Creative Cloud лиценз шаарддаг.

3.4 Тэмдэгт танилтын алгоритмууд

Оптик тэмдэгт таних алгоритмууд нь уламжлалт зураг боловсруулах, машин сургалтанд суурилсан арга эсвэл гүнзгий суралцах аргад суурилсан байж болно. Тэмдэгт таних алгоритмын хэд хэдэн анги байдаг ч тэдгээр нь бүгд өндөр чанартай дүрс оруулахыг шаарддаг. Дуу чимээ ихтэй, тод бус зураг нь чимээ шуугиангүй, тод зурагтай харьцуулахад өндөр магадлалтайгаар буруу илрнэ. Мөн таних чанарт тэмдэгтүүдийн налуу, хэмжээ нөлөөлдөг. Тиймээс таних алгоритмыг ашиглахын өмнө зургийг урьдчилан боловсруулах шаардлагатай.

3.4.1 Загвар тааруулах

Тэмдэгтүүдийг таних аргаас матриц тааруулах нь илүү энгийн бөгөөд түгээмэл байдаг. Тааруулах нь OCR сканнер ямар тэмдэгт гэж харж байгааг тэмдэгтийн матриц эсвэл загваруудын сантай харьцуулдаг. Тухайн зураг ижил төстэй байдлын түвшинд эдгээр тогтоосон цэгийн матрицуудын аль нэгтэй таарч байвал компьютер тэр зургийг харгалзах ASCII тэмдэгт гэж тэмдэглэнэ.



ЗУРАГ 3.10: Загвар тааруулах алгоритмын ажлын урсгалын диаграм

Загвар тааруулах алгоритм нь дараах алхмуудыг хэрэгжүүлдэг.

- Нэгдүгээрт, илрүүлсэн тэмдэгтийн дүрсийг сонгоно.
- Үүний дараа зургийг эхний загварын хэмжээтэй болгож өөрчлөнө.
- Зургийн хэмжээг анхны загвар (эх) зургийн хэмжээтэй дахин тохируулсны дараа тохирох хэмжигдэхүүнийг тооцоолно.
- Дараа нь олсон хамгийн өндөр тохирохыг хадгална. Хэрэв зураг таарахгүй бол гурав дахь алхамыг давтана уу.
- Хамгийн сайн тохирохын индексийг танигдсан тэмдэгт болгон хадгална.

Хүлээн зөвшөөрөгдөхийн тулд одоогийн оролтын тэмдэгтийг загвар бүртэй харьцуулж яг таарч байгаа эсвэл оролтын тэмдэгтийн хамгийн ойр дүрслэл бүхий загварыг олно. Хэрэв $I(x, y)$ нь оролтын тэмдэгт, $Tn(x, y)$ нь загвар n бол тохирох функц нь $s(I, Tn)$ нь загвар n нь оролтын тэмдэгттэй хэр таарч байгааг харуулсан утгыг буцаана. Илүү нийтлэг тохирох функцууд нь дараах томъёо дээр суурилдаг.

$$s(I, Tn) = \sum_{i=0}^w \sum_{j=0}^h |I(i, j) - Tn(i, j)| \quad (1)$$

$$s(I, Tn) = \sum_{i=0}^w \sum_{j=0}^h (I(i, j) - Tn(i, j))^2 \quad (2)$$

$$s(I, Tn) = \sum_{i=0}^w \sum_{j=0}^h I(i, j) Tn(i, j) \quad (3)$$

$$s(I, Tn) = \frac{\sum_{i=0}^w \sum_{j=0}^h (I(i, j) - I) (Tn(i, j) - Tn)}{\sqrt{\sum_{i=0}^w \sum_{j=0}^h (I(i, j) - I)^2} \sqrt{\sum_{i=0}^w \sum_{j=0}^h (Tn(i, j) - Tn)^2}} \quad (4)$$

ЗУРАГ 3.11: Загвар тааруулах томъёо

Тэмдэгтийг таних нь аль Tn нь тохирох функцийн хамгийн сайн утгыг өгөх $s(I, Tn)$ -ийг тодорхойлох замаар хийгддэг. Хадгалсан загварууд нь ижил эсвэл төстэй фонгтой байх тохиолдолд л энэ арга амжилттай болно. Загвар тохирохыг хоёртын, босго тэмдэгтүүд эсвэл саарал түвшний тэмдэгтүүд дээр хийж болно. Саарал түвшний тэмдэгтүүдийн хувьд Нормалжуулсан корреляцийг ашиглах нь илүү түгээмэл байдаг, учир нь энэ нь оролтын тэмдэгт болон хадгалагдсан загвар хоорондын тод байдал, ялгаатай байдлын өөрчлөлтийг эсэргүүцэх чадварыг сайжруулдаг.

3.4.2 Fuzzy logic

Fuzzy Logic нь өнөө үед олон талбарт олон төсөл, хэрэглээнд зориулагдсан алдартай бөгөөд амжилттай шийдэл юм. Бид суулгагдсан систем, өгөгдлийн кластер хийх эсвэл зураг боловсруулах зэрэг өөр өөр салбарт олон тооны бодит хэрэглээг олж чадна. Мянга мянган патент бүхий Fuzzy техникийг ашигладаг олон тооны арилжааны бүтээгдэхүүнүүд байдаг.

Fuzzy logic ашиглан функцуудыг гаргаж авснаар мэдрэлийн сүлжээ эсвэл k-хамгийн ойрын хөрш аргуудтай холбоотойгоор тэмдэгтэт танилтыг сайн ойлгох ба эцэст нь илүү сайн шийдлийг гаргах болно. Мэдрэлийн сүлжээ болон k-хамгийн ойрын хөршийн аргуудад шаардагдах өргөн хүрээний сургалтын үе шатуудаас зайлсхийх боломжтой.

Ангилалын үе шатанд гар аргаар боловсруулсан fuzzy logic ангиллын дүрмийг ашиглан шинж чанарыг задлах үр дүнд дүрслэгдсэн тэмдэгтийн хамгийн их магадлалтай танигдсан тэмдгийг тодорхойлно.

	Сургалтын багц		
	Нийт тоо	Зөв ангилсан	Амжилтын хувь
Үсэг/тоон ангилагч	150	150	100.00%
Үсгийн ангилагч	230	230	100.00%
Тоон ангилагч	380	379	99.70%

	Туршилтын багц		
	Нийт тоо	Зөв ангилсан	Амжилтын хувь
Үсэг/тоон ангилагч	50	49	98.00%
Үсгийн ангилагч	115	113	98.30%
Тоон ангилагч	165	160	97.00%


ЗУРАГ 3.12: Fuzzy logic ангилагчийг ашиглан гарсан үр дүн

3.4.3 Шинж чанарыг задлах

Fuzzy logic шинж чанарыг задлах дүрмүүд нь шинж чанарыг задлах алгоритмын үндэс болдог. Онцлогыг задлах үе шатанд тэмдэгт бүрийг шинж чанарын вектор хэлбэрээр төлөөлдөг бөгөөд энэ нь түүний таних тэмдэг болдог. Гол зорилго нь хамгийн бага элементээр таних хурдыг нэмэгдүүлэх, ижил тэмдгийн олон тохиолдлуудад ижил төстэй шинж чанаруудын багцыг бий болгох функцүүдийн багцыг гаргаж авах явдал юм. Өндөр хувьсах чадвартай гар бичмэлийн шинж чанараас шалтгаалан эдгээр шинж чанарыг олж авах нь хэцүү ажил юм. Онцлогыг задлах аргууд нь оролтын баримт бичгийн дүрсэнд дүн шинжилгээ хийж, тэмдэгтийг онцгойлон ялгаж, ангилах шинж чанаруудын багцыг сонгоно. Эдгээр нь гурван төрлийн шинж чанарт суурилдаг:

Тэмдэгтийн дүрслэлд ашигладаг гол статистик шинж чанаруудыг доор харуулав.


Бүсчлэл(Zoning) Тэмдэгтийн хүрээ нь хэд хэдэн давхардсан болон давхцдаггүй бүсэд хуваагддаг. Дүрслэл үүсгэхийн тулд цэгийн нягтрал эсвэл өөр өөр бүс нутгийн зарим шинж чанарыг шинжилдэг. Жишээ нь: контурын чиглэлийн шинж чанарууд нь дүрийн контурын чиглэлийг хэмждэг. [9] дүрсийг тэгш өнцөгт ба диагональ бүсэд хувааж, эдгээр бүс дэх гинжин кодын гистограммыг тооцоолох замаар үүсдэг. Гулзайлтын цэгийн онцлог нь 10-р зурагт үзүүлсэн шиг өндөр муруйлт, төгсгөлийн цэгүүд болон салаа цэгүүдийг заана.



ЗУРАГ 3.13: Хүрээ бүхий контурын чиглэл ба гулзайлтын онцлог

Төлөвлөлт ба профайл(Projections and profile) Тэмдэгтийн оролтын өгөгдлийг хоёр хэмжээст дүрст нэг хэмжээст дохио өгөх янз бүрийн чиглэлд пикселийн саарал утгыг шугамууд дээр проекцлох замаар дүрсэлж болно. Төсөөллийг ашиглах үндсэн санаа нь 2 хэмжээст дохио болох тэмдэгтийн дүрсийг 1 хэмжээст дохио хэлбэрээр дүрсэлж болно. Эдгээр шинж чанарууд нь дуу чимээ, хэв гажилтаас хамааралгүй боловч эргэлтээс хамаардаг. Проекцийн гистограмм нь тэмдэгтийн зургийн багана, мөр тус бүрийн пикселийн тоог тоолдог. Проекцийн гистограмм нь "m" ба "n" зэрэг тэмдэгтүүдийг салгах боломжтой Профайл нь тэмдэгтийн зургийн хязгаарлах хайрцаг ба тэмдэгтийн ирмэгийн хоорондох пикселийн тоог (зай) тооцдог. Профайл нь тэмдэгтүүдийн гадаад хэлбэрийг сайн дүрсэлж, "p" болон "q" гэх мэт олон тооны үсгийг ялгах боломжийг олгодог.

Солбицох болон зай(Crossings and distances) Энэ нь контурыг тодорхой чиглэлд шугамын сегментээр огтолж буй тоог хэлнэ. Өгөгдсөн хилээс шугамын сегментийн зайг шинж чанаруудын нэг болгон ашиглаж болно. Скриптийн дээд, доор, дундуур хэвтээ босго тогтоож болно. Онцлогын утга нь скриптийн босгыг давсан тоо, тоо юм.



ЗУРАГ 3.14: Солбицох болон зайны(crossings and distances) жишээ

3.5 Оптик тэмдэгт таних техникүүд

3.5.1 OCRopus

OCRopus нь судлаачид болон компаниудад OCR бүрэлдэхүүн хэсгүүдийг хялбархан үнэлж, дахин ашиглах боломжийг олгодог нээлттэй эхийн OCR систем юм. Баримт бичигтээ хэрэглэхийн тулд зурагны урьдчилсан боловсруулалт хийх, шинэ загваруудыг сургах шаардлагатай. Таних скриптүүдээс гадна үндсэн үнэнийг засах, засах, алдааны түвшинг хэмжих, төөрөгдлийн матрицыг тодорхойлох, ашиглах, засварлахад хялбар хэд хэдэн скрипт байдаг.



ЗУРАГ 3.15: OCRopus системийн бүрдүүлдэг урсгалын диаграм

Хуудасны бүтцийн шинжилгээ, текстийн мөрийг таних, статистик хэлний загварчлал гэсэн гурван үндсэн бүрэлдэхүүн хэсгээс бүрдэнэ. (Үүнээс гадна энэ нь урьдчилсан боловсруулалт болон ангилагчийг хослуулах хэрэгслүүдийг агуулдаг.)

Физик байршлын шинжилгээ нь текстийн багана, текстийн блок, текстийн мөр, унших дарааллыг тодорхойлох үүрэгтэй.


Текстийн мөрийг таних нь мөр бүрт агуулагдаж буй текстийг таних үүрэгтэй (мөрүүд босоо эсвэл баруунаас зүүн тийш байж болно гэдгийг анхаарна уу) болон таних боломжит хувилбаруудыг таамаглалын график болгон төлөөлөх үүрэгтэй.

Хэлний статистик загварчлал нь өөр таних таамаглалыг хэл, үгийн сан, дүрэм, баримт бичгийн домэйны талаарх өмнөх мэдлэгтэй нэгтгэдэг.

3.5.2 Kraken

Kraken бол түүхийн болон латин бичгээс бусад материалд тохирсон turn-key OCR систем юм. Linux болон OSX дээр ажиллуулахын тулд хэд хэдэн гадаад санг шаарддаг CUDA-г дэмждэг turnket OCR тогтолцоо нь Kraken юм. Үүнийг PIP эсвэл Anaconda-аар суулгаж болох бөгөөд таних загваруудыг гадны эх сурвалжаас ачаалах ёстой. Төсөл нь нийтийн загварын агуулахтай хэдий ч одоогоор зөвхөн англи хэлний ерөнхий загвар болон сири хэл дээрх бичвэрийн загварыг агуулсан байна.

OCR програм хангамжийн бүтэц нь үндсэн боловсруулалт, сегментчилэл, таних зэрэг олон алхмаас бүрддэг бөгөөд эдгээр үе шат бүр нь өмнөх алхамын гаралтыг авдаг ба заримдаа тодорхой хувиргалтыг хэрхэн гүйцэтгэхийг тодорхойлсон загвар, загвар гэх мэт нэмэлт файлуудаас бүрддэг.



ЗУРАГ 3.16: Kraken

Оптик тэмдэгтийг таних нь кракен хоёртын хувилбар (өнгөт болон саарал өнгийн зургийг битональ болгон хувиргах), байршлын шинжилгээ/хуудасны сегментчилэл (зурагнаас топологийн текстийн мөрийг задлах), таних (текстийн шугамын зургийг оруулах) зэрэг олон алхмуудыг дараалан гүйцэтгэх явдал юм. ангилагч), эцэст нь үр дүнг hOCR эсвэл ALTO гэх мэт тохирох формат руу цуваа болгоно.

Kraken-ийн үндсэн шинж чанарууд нь:

- Бүрэн сургах боломжтой байрлалын шинжилгээ, дүрийг таних
- Баруунаас зүүн тийш, BiDi, дээрээс доош скриптийг дэмждэг
- ALTO, PageXML, abbyXML, hOCR гаралт
- Үг хязгаарлах хайрцаг, тэмдэгтийн зүсэлт
- Олон скрипт таних дэмжлэг
- Загварын файлуудын нийтийн сан
- Хөнгөн загварын файлууд
- Хувьсагчийг таних сүлжээний архитектурууд
- Татаж авах хүсэлт болон кодын хувь нэмэр үргэлж баяртай байдаг.

3.5.3 Calamari OCR


OCRopus-ийн өөр нэг диссидент, Python 3-д суурилсан Calamari OCR нь зөвхөн CLI-д суурилсан хүрээ бөгөөд мөн Kraken-ээс гаралтай. Энэ нь орчин үеийн эх сурвалжаас илүү түүхэн эх сурвалжийг онцолсон загвар агуулахыг санал болгодог бөгөөд франц хэл нь англи хэлнээс өөр үндсэн хэл нь болдог. Calamari бол Tensorflow-д хэрэгжсэн хамгийн сүүлийн үеийн Deep Neural Networks (DNN)-ийг ашигладаг нээлттэй эхийн OCR программ хангамж бөгөөд бэлтгэл сургуулилт, санал хураалт гэх мэт арга техникийг дэмждэг.

3.5.4 Keras OCR


Python-д суурилсан гүнзгий сургалтын API Keras нь OCR (tf.keras 2.1-д зориулагдсан) болон keras-ocr зэрэг хэд хэдэн модульчлагдсан FOSS агуулахад ашигласан текстийг танихад зориулсан эргэлтийн давтагдах мэдрэлийн сүлжээг (CRNN) санал болгодог бөгөөд үүнийг хийхэд хялбар байдаг. Шинэ систем болгон хэрэгжүүлж, PyTorch Character-Region Awareness For Text detection (CRAFT) текст илрүүлэгчийг ашиглана.

3.5.5 Tesseract OCR

Tesseract нь янз бүрийн үйлдлийн системд зориулсан тэмдэгт таних оптик хөдөлгүүр юм. Энэ нь Apache лицензийн дагуу гаргасан үнэгүй програм хангамж юм. Анх 1980-аад онд Hewlett-Packard компани өмчийн программ хангамж болгон хөгжүүлсэн бөгөөд 2005 онд нээлттэй эх хэлбэрээр гаргасан бөгөөд 2006 оноос хойш Google хөгжүүлж байна. Тессеракт алгоритм нь Google Code дээр байдаг бөгөөд хамгийн сайн нээлттэй эхийн OCR-ийн нэг юм.



ЗУРАГ 3.17: Tesseract системийн архитектур




ЗУРАГ 3.18: Tesseract системийн ажиллагаа

3.5.6 EasyOCR

Jaidev AI нь 2020 онд байгуулагдсан. Бидний зорилго бол хиймэл оюун ухааны ашиг тусыг дэлхий нийтэд түгээх явдал юм. Эхний төсөл нь EasyOCR нэртэй нээлттэй эхийн OCR номын сан юм. Бид програм хангамжийг хамгийн сүүлийн үеийн гүйцэтгэлээр хангахын зэрэгцээ ашиглахад маш хялбар байх ёстой гэсэн философитойгоор бүтээдэг. Энэ нь удахгүй болох хиймэл оюун ухааны хувьсгалд бэлтгэхийн тулд хүн бүрт хиймэл оюун ухааны хүртээмжийг нэмэгдүүлэх зорилготой юм.

Нээлттэй эхийн төсөл амжилттай хэрэгжсэний дараа бид хүн бүрт кодгүй AI платформоор хангаснаар AI-г илүү өргөн хүрээний хүмүүст түгээхийг хүсч байна. Манай кодгүй OCR үйлчилгээг 2021 оны 5-р сард OCR технологийг өөрсдийн хэрэглээний тохиолдолд ашиглахыг зорьж буй хэрэглэгчдэд зориулан эхлүүлсэн.

Латин, хятад, араб, деванагари, кирилл гэх мэт 80 гаруй хэлийг дэмждэг, бүх алдартай бичгийн скриптүүдтэй ашиглахад бэлэн OCR. Линукс дээрx PIP-д суурилсан үйлдлийн хувьд EasyOCR нь Windows дээр PyTorch-ээр ажилладаг, Docker-ээр дамжуулан хэрэгжих боломжтой ба CUDA-г дэмждэг. EasyOCR нь олон хэлийг нэгэн зэрэг унших боломжтой боловч тэдгээр нь хоорондоо нийцтэй байх ёстой. Англи хэл нь бүх хэлтэй нийцдэг. Ихэнх тэмдэгтүүд (жишээ нь, латин үсэг) өөр хоорондоо тохирдог хэлүүд. EasyOCR нь танд шаардлагатай загварын файл байгаа эсэхийг шалгаж, автоматаар татаж авах болно. Дараа нь энэ нь загвараа санах ойд ачаалах бөгөөд энэ нь таны техник хангамжаас хамааран хэдэн секунд болно. Үүнийг хийсний дараа та энэ мөрийг дахин ажиллуулахгүйгээр хүссэн олон зургийг уншиж болно.



ЗУРАГ 3.19: EasyOCR-н фреймворк

3.5.7 Технкийн харьцуулалтууд

	Зөвшөөрдөг зургийн өргөтгөл
Tesseract	.bmp, .png, .pnm, .jif, .jpeg, .tiff
Kraken	.jpeg, .png, .gif
Calamari	.png болон түүнд харгалзах .gt .txt
EasyOCR	.png, .jpeg, jpg...
Keras	jpeg, png, bmp, gif.

ЗУРАГ 3.20: Дэмждэг зургийн өртөгтгөл

	Тоон дээрх алдааны түвшин	Үсэг дээрх алдааны түвшин	CPU	GPU
Tesseract	5.50%	0.70%	0.3 сек/зурал	0.25 сек/зурал
EasyOCR	1.90%	4.30%	0.82 сек/зурал	0.07 сек/зурал

ЗУРАГ 3.21: Алдааний түвшин болон GPU, CPU дээрх зураг танилтын хугацаа

	Зураг(тоо)	Хугацаа (секунд)	Миллсекунд/зураг	Төхөөрөмж
Tesseract	500	131.65	263.31	CPU
EasyOCR	500	17.37	34.74	GPU(T4)
EasyOCR	500	71.49	142.98	CPU

ЗУРАГ 3.22: 500 зураг таньсан жишээ

БҮЛЭГ 4

Туршилт үр дүн

4.1 Оптик тэмдэгт таних туршилт

4.1.1 EasyOCR ашигласан туршилт

Одоогоор EasyOCR суулгах 3 боломжит арга бий.

1. pip багц ашиглах
2. эх сурвалжаас бүтээх эсвэл
3. Docker контейнерт ажиллуулах.

4.1.2 Орчин бэлдэх

Анаconda суулгах: Анаконда нь Python/R мэдээллийн шинжлэх ухаан болон машин сургалтыг нэг машин дээр гүйцэтгэх хамгийн хялбар аргыг санал болгодог.

Jupyter: JupyterLab нь notebook, код, өгөгдөлд зориулсан хамгийн сүүлийн үеийн вэбд суурилсан интерактив хөгжүүлэлтийн орчин юм. Түүний уян хатан интерфэйс нь хэрэглэгчдэд мэдээллийн шинжлэх ухаан, шинжлэх ухааны тооцоолол, тооцооллын сэтгүүл зүй, машин сургалтын чиглэлээр ажлын урсгалыг тохируулах, зохицуулах боломжийг олгодог. Модульчлагдсан загвар нь функцийг өргөжүүлэх, баяжуулах өргөтгөлүүдийг урьж байна.

- Command prompt цонхыг нээн дараах командыг өгөх

```
conda create -n env_easyocr python==3.6.5
```

```
(base) anujinbathileg@Anujins-MacBook-Air: ~ % conda create -n env_easyocr python==3.6.5
Collecting package metadata (current_repodata.json): done
Solving environment: failed with repodata from current_repodata.json, will retry with next repodata source.
Collecting package metadata (repodata.json): done
Solving environment: done

The following packages will be downloaded:
```

package	build	size
ca-certificates-2022.3.18	hecd8cb5_0	122 KB
certifi-2021.5.30	py36hecd8cb5_0	138 KB
libcxx	h8a44026_1007	43 KB
libedit	hca72f7f_2	856 KB
libffi-3.2.1	h1de35cc_0	2.0 MB
ncurses-6.3	py36hecd8cb5_0	1.8 MB
openssl-1.0.2u	hc167b69_1	12.0 MB
python-3.6.5	h1de35cc_5	316 KB
readline-7.0	py36hecd8cb5_0	777 KB
setuptools-58.0.4	hffcf06c_0	1.3 MB
sqlite-3.33.0	pyhd3eb1b0_0	33 KB
wheel-0.37.1	h4dc903c_4	96 KB
zlib-1.2.11		
Total:		19.4 MB

```

The following NEW packages will be INSTALLED:
ca-certificates pkgs/main/osx-64::ca-certificates-2022.3.18-hecd8cb5_0
certifi pkgs/main/osx-64::certifi-2021.5.30-py36hecd8cb5_0
libcxx pkgs/main/osx-64::libcxx-12.0.0-h2f01279_0
libedit pkgs/main/osx-64::libedit-3.1.20210910-hca72f7f_2
libffi pkgs/main/osx-64::libffi-3.2.1-h0a44026_1007
ncurses pkgs/main/osx-64::ncurses-6.3-hca72f7f_2
openssl pkgs/main/osx-64::openssl-1.0.2u-h1de35cc_0
pip pkgs/main/osx-64::pip-21.2.2-py36hecd8cb5_0
python pkgs/main/osx-64::python-3.6.5-hc167b69_1
readline pkgs/main/osx-64::readline-7.0-h1de35cc_5
setuptools pkgs/main/osx-64::setuptools-58.0.4-py36hecd8cb5_0
sqlite pkgs/main/osx-64::sqlite-3.33.0-hffcf06c_0
tk pkgs/main/osx-64::tk-8.6.11-h7bc2e8c_0
wheel pkgs/main/noarch::wheel-0.37.1-pyhd3eb1b0_0
xz pkgs/main/osx-64::xz-5.2.5-h1de35cc_0
zlib pkgs/main/osx-64::zlib-1.2.11-h4dc903c_4

```

- Easyocr идэвхжүүлэх

activate env_easyocr

```

Downloading and Extracting Packages
sqlite-3.33.0 | 1.3 MB | ##### | 100%
openssl-1.0.2u | 2.0 MB | ##### | 100%
ncurses-6.3 | 856 KB | ##### | 100%
certifi-2021.5.30 | 138 KB | ##### | 100%
wheel-0.37.1 | 33 KB | ##### | 100%
readline-7.0 | 316 KB | ##### | 100%
pip-21.2.2 | 1.8 MB | ##### | 100%
ca-certificates-2022 | 122 KB | ##### | 100%
zlib-1.2.11 | 96 KB | ##### | 100%
python-3.6.5 | 12.0 MB | ##### | 100%
libffi-3.2.1 | 43 KB | ##### | 100%
setuptools-58.0.4 | 777 KB | ##### | 100%
Preparing transaction: done
Verifying transaction: done
Executing transaction: done
#
# To activate this environment, use
#
# $ conda activate env_easyocr
#
# To deactivate an active environment, use
#
# $ conda deactivate

```

ЗУРАГ 4.1: EasyOCR идэвхжүүлэх

-PyTorch нь GPU болон CPU ашиглан гүнзгий суралцахад зориулагдсан оновчтой тензор сан юм. Зөвхөн сру ашиглахаар зааж өглөө.

conda install pytorch torchvision cpuonly -c pytorch

```

(base) anujinbatbileg@Anujins-MacBook-Air ~ % conda install pytorch torchvision cpuonly -c pytorch
Collecting package metadata (current_repodata.json): done
Solving environment: done

## Package Plan ##

  environment location: /Users/anujinbatbileg/opt/anaconda3

added / updated specs:
- cpuonly
- pytorch
- torchvision

The following packages will be downloaded:

package | build | size
-----|-----|-----
conda-4.12.0 | py39hcd8cb5_0 | 14.5 MB
cpuonly-2.0 | 0 | 2 KB
ffmpeg-4.3 | h0a44026_0 | 10.1 MB
gettext-0.21.0 | h7535e17_0 | 2.6 MB
gnutls-3.6.15 | hed9c8bf_0 | 974 KB
lame-3.100 | h1de35cc_0 | 316 KB
libidn2-2.3.2 | h9ed2024_0 | 85 KB
libtasn1-4.16.0 | h9ed2024_0 | 53 KB
libunistring-0.9.10 | h9ed2024_0 | 519 KB
nettle-3.7.3 | h230ac6f_1 | 380 KB
openh264-2.1.1 | h8346a28_0 | 655 KB
pytorch-1.11.0 | py3.9_0 | 78.0 MB
pytorch-mutex-1.0 | cpu | 3 KB
torchvision-0.12.0 | py39_cpu | 7.2 MB
Total: 107.2 MB

The following NEW packages will be INSTALLED:

cpuonly | pytorch/noarch::cpuonly-2.0-0
ffmpeg | pytorch/osx-64::ffmpeg-4.3-h0a44026_0
gettext | pkgs/main/osx-64::gettext-0.21.0-h7535e17_0
gnutls | pkgs/main/osx-64::gnutls-3.6.15-hed9c8bf_0
lame | pkgs/main/osx-64::lame-3.100-h1de35cc_0
libidn2 | pkgs/main/osx-64::libidn2-2.3.2-h9ed2024_0
libtasn1 | pkgs/main/osx-64::libtasn1-4.16.0-h9ed2024_0
libunistring | pkgs/main/osx-64::libunistring-0.9.10-h9ed2024_0
nettle | pkgs/main/osx-64::nettle-3.7.3-h230ac6f_1
openh264 | pkgs/main/osx-64::openh264-2.1.1-h8346a28_0
pytorch | pytorch/osx-64::pytorch-1.11.0-py3.9_0
pytorch-mutex | pytorch/noarch::pytorch-mutex-1.0-cpu
torchvision | pytorch/osx-64::torchvision-0.12.0-py39_cpu

```

ЗУРАГ 4.2: pytorch суулгах

-pip нь програм хангамжийн багцуудыг суулгах, удирдахад ашигладаг Python хэл дээр бичигдсэн багц удирдлагын систем юм. Pip ашиглан easyocr суулгах.

```
pip install easyocr
```

```
(base) anujinbatbileg@Anujins-MacBook-Air ~ % pip install easyocr
Collecting easyocr
  Using cached easyocr-1.4.1-py3-none-any.whl (63.6 MB)
Requirement already satisfied: torchvision>=0.5 in ./opt/anaconda3/lib/python3.9/site-packages (from easyocr) (0.12.0)
Requirement already satisfied: scikit-image in ./opt/anaconda3/lib/python3.9/site-packages (from easyocr) (0.18.0)
Collecting Pillow<8.3.0
  Downloading Pillow-8.2.0-cp39-cp39-macosx_10_10_x86_64.whl (2.8 MB)
    | 2.8 MB 1.1 MB/s
Requirement already satisfied: numpy in ./opt/anaconda3/lib/python3.9/site-packages (from easyocr) (1.20.3)
Requirement already satisfied: torch in ./opt/anaconda3/lib/python3.9/site-packages (from easyocr) (1.11.0)
Requirement already satisfied: PyYAML in ./opt/anaconda3/lib/python3.9/site-packages (from easyocr) (6.0)
Collecting opencv-python-headless
  Downloading opencv_python_headless-4.5.5.64-cp36-abi3-macosx_10_15_x86_64.whl (46.3 MB)
    | 46.3 MB 1.5 MB/s
Collecting python-bidi
```

ЗУРАГ 4.3: pip ашиглан easyocr суулгах

-Прожет-н замыг зааж өгөх Jupyter Notebook нь тооцооллын баримт бичгийг үүсгэх, хуваалцах анхны вэб програм юм. Энэ нь энгийн, хялбаршуулсан, баримт бичигт суурилсан туршлагыг санал болгодог.

```
jupyter notebook
```

```
(base) anujinbatbileg@Anujins-MacBook-Air ~ % cd downloads
(base) anujinbatbileg@Anujins-MacBook-Air downloads % cd EasyOCR-master
(base) anujinbatbileg@Anujins-MacBook-Air EasyOCR-master % jupyter notebook
[I 22:06:03.187 NotebookApp] Writing notebook server cookie secret to /Users/anujinbatbileg/Library/Jupyter/runtime/notebook_cookie_secret
[I 22:06:03.28 22:06:04.413 LabApp] JupyterLab extension loaded from /Users/anujinbatbileg/opt/anaconda3/lib/python3.9/site-packages/jupyterlab
[I 22:06:03.28 22:06:04.413 LabApp] JupyterLab application directory is /Users/anujinbatbileg/opt/anaconda3/share/jupyter/lab
[I 22:06:04.418 NotebookApp] Serving notebooks from local directory: /Users/anujinbatbileg/Downloads/EasyOCR-master
[I 22:06:04.418 NotebookApp] Jupyter Notebook 6.4.0 is running at:
[I 22:06:04.418 NotebookApp] http://localhost:8888/?token=4985fed0713cbb185b60adc3981164295a938d8ce20457e
[I 22:06:04.418 NotebookApp] or http://127.0.0.1:8888/?token=4985fed0713cbb185b60adc3981164295a938d8ce20457e
[I 22:06:04.419 NotebookApp] Use Control-C to stop this server and shut down all kernels (twice to skip confirmation).
[C 22:06:04.427 NotebookApp]
```

ЗУРАГ 4.4: pip ашиглан easyocr суулгах

4.1.3 Монгол хэлний өгөгдөл бэлтгэх

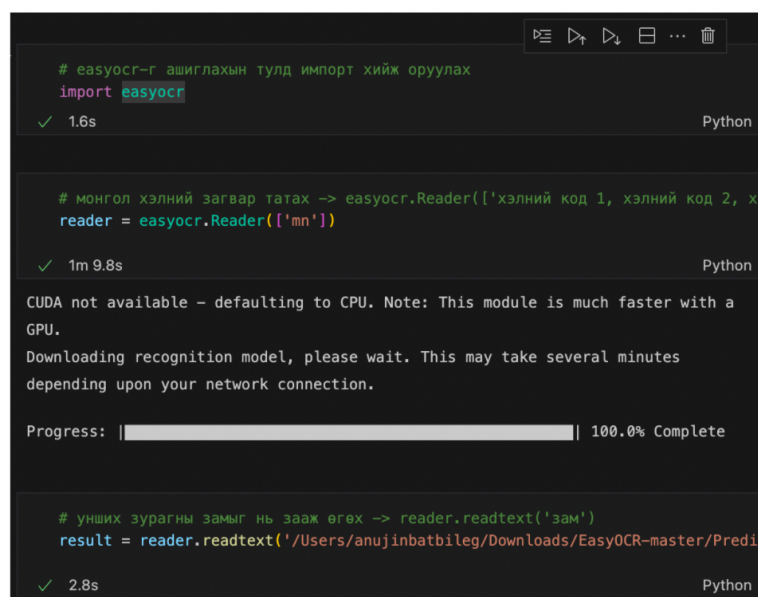
Монгол хэлд ашиглагддаг тэмдэгтүүдийг том жижигээр нь .txt файлд хадгалах. А,Б,В,Г,Д,Е,Ё,Ж,З,И,Й,К,Л,М,Н,О,Ө,П,Р,С,Т,У,Ү,Ф,Х,Ц,Ч,Ш,Щ,Ъ,Ы,Ь,Э,Ю,Я,а,б,в,г,д,е,ё,ж,з,и,й,к,л,м,н,о,ө,п,р,с,т,у,ү,ю,ф,х,ц,ч,ш,щ,ъ,ы,ь,э,ю,я

Үгийн толь үүсгэх: 128665 үгтэй толь үүсгэгдсэн. Үүнд, нь,гэж,ч,юм,тэр,энэ,л,би,нэг,минь,байна,хоёр,хүн,шиг,чи,чинь,их,дээр,бол,юу,байгаа,хаан,дээ,уу,гээд,байсан,вэ,билээ,бас,нэгэн,одоо,байх,гэв,хар,с айн,биш,сайхан,та,хэмээн. . . гэх хэлбэртэй байна. Жишээлбэл, сургууль гэх үгийг сургууль, сургуульд, сургуульдаа, сургуультай, сургуульд, Сургууль гэх зэргээр үүсгэгдсэн.

EasyOCR-г ашиглахын тулд эхлээд үүнийг импортлох хэрэгтэй. Дараа нь ямар хэлний загвар ашиглахаа зааж өгнө. Ингэхдээ олон хэл ашиглаж болох ба одоогоор 80+ хэлний загваруудыг өргөтгөн хөгжүүлж байна.

```
elif set(lang_list) & set(cyrillic_lang_list):
    self.setModelLanguage('cyrillic', lang_list, cyrillic_lang_list+['en'],
                           ['ru', 'rs_cyrillic', 'be', 'bg', 'uk', 'mn', 'en'])
    model = recognition_models['gen1']['cyrillic_g1']
    recog_network = 'generation1'
```

ЗУРАГ 4.5: Монгол хэлний загвар танилтын загвар



ЗУРАГ 4.6

Үүний дараагаар унших зурагны замыг нь зааж өгсөн. Үр дүн, Стандарт гаралт нь жагсаалтын форматтай бөгөөд зүйл бүр нь текст хайрцагны координат [x,y], текст болон загварт confident жагсаалтыг тус тус илэрхийлдэг.

```
[[[23, 9], [69, 9], [69, 23], [23, 23]], 'Шутис', 0.7607140820292146),
([[83, 0], [496, 0], [496, 26], [83, 26]], 'хөдөлмөрийн ГАВьяАны УЛААН
Тугийн одонт', 0.6607978787984091),
([[85, 26], [496, 26], [496, 50], [85, 50]], 'Монгол Улсын Шинжлэх УХААН',
0.6185142440145647),
([[83, 54], [418, 54], [418, 82], [83, 82]], 'технологийн их Сургуул
ь', 0.5413010643394385),
([[86, 92], [492, 92], [492, 116], [86, 116]], 'мэдээлэл, холбоо
ны технологийн Сургууль', 0.5765828193163117)]
```



ЗУРАГ 4.7: Туршилт



ӨҮвь26,;-ФЦЖурам+

Улаанбаатар хот

123Т0хирох67утг@

Оюут@ н сур агч

ЗУРАГ 4.8: Туршилтад ашигласан зургууд

Файлын нэр	Бодит утга	EasyOCR таамаглал	Tesseract таамаглал
sict.png	ШУТИС ХӨДӨЛМӨРИЙН ГАВЬЯАНЫ УЛААН ТУГИЙН ОДОНТ МОНГОЛ УЛСЫН ШИНЖЛЭХ УХААН ТЕХНОЛОГИЙН СУРГУУЛЬ	Шутис хөдөлмөрийн Гавьяаны Улаан Тугийн одонт Монгол Улсын Шинжлэх Ухаан технологийн их Сургууль мэдээлэл, холбооны технологийн Сургууль	ХөДөлмөрийн ГАВЬЯАНЫ УЛААН ТУГИЙН ОДОНТ МОНГОЛ УЛСЫН ШИНЖЛЭХ УХААН ТЕХНОЛОГИЙН ИХ СУРГУУЛЬ МЭДЭЭЛЭЛ, ХОЛБООНЫ ТЕХНОЛОГИЙН СУРГУУЛЬ
juram.png	ӨҮвь26,;-ФЦЖурам+	ЭҮвь26,;-ФЦЖурам+	Б }/632 6/ ф[/]/{}'дм+
ub.png	Улаанбаатар хот	Улаанбаатар хот	Улаанбаатар хот
utga.png	123Т0хирох67утг@	1131плиРоЮ(7'тГ0	) УТОХИРОХЬ7УТГ@
oyutansuragch.png	Оюут@ н сур агч	Оюут@ Н сур агч	Оюут@ н сур агч

ЗУРАГ 4.9: Туршилтын харьцуулалт

БҮЛЭГ 5

Дүгнэлт

5.1 Дүгнэлт

Монгол хэлийг дэмждэг EasyOCR, Tesseract тэмдэгт танилтын технологийг ашиглан үг, тэмдэгт, тоо болон ялгаатай фонт-г ашиглан зургаас текст таних туршилт хийсэн. Тус ажлын хүрээн олж авсан мэдлэг, дадлагыг доор тусган орууллаа:

- Тэмдэгт танилтад ашиглагддаг техникүүдийн ажиллагаа, ашигладаг алгоритм, алхам нь тэмдэгт танилтын үр дүнд хэрхэн нөлөөлж буй
- EasyOCR, Tesseract техникүүд нь монгол хэлний өгөгдлийн багц хэрхэн бэлтгэж ашигладаг талаар
- Туршилтын үр дүнг дүгнэхэд том жижиг үсгийн танилтын чадвар нь Tesseract илүү бодит үр дүнг харуулсан
- Tesseract-д фонт болон үсгийн налуу байдал ихээхэн нөлөө үзүүлсэн
- EasyOCR-н гаралтаас харахад тухайн үгийг өөрийн толиос хайж үг олноогүй тохиолдолд тэмдэгтүүдийг хооронд нь холбосон
- EasyOCR-н үсэг, тэмдэгт, тоо хольсон зургаас таних чадвар нь Tesseract-тай харьцуулахад танилтын түвшин харьцангуй сайн үр дүнг гаргасан

5.2 Ашигласан материал, ном зүй

2. <http://www.google.mn/>

6. <http://ieeexplore.ieee.org>

7. http://en.wikipedia.org/wiki/Data_mining

Mori, S.et.al. : Historical Review of OCR Research and Development. Proceeding IEEE, Vol.8
1058.

Optical Character Recognition By Using Template Matching (Alphabet), Universiti Malaysia Po

Optical Character Recognition Using Automatically Generated Fuzzy Classifiers, 2011 Eighth I
452, 26 – 28 July 2011